



# AWSエンジニアのための Cloud Run ハンズオン

Google Cloud / Cloud Run を、AWS との違いから学ぶ

TypeScript + Hono / Artifact Registry / Cloud Run

# 目次

---

はじめに

0. 事前準備

## 座学パート

1. AWSとGoogle Cloudの考え方の違い

2. Dockerのおさらいとコンテナ起動

3. Cloud Runとは

## ハンズオンパート

4. Cloud Runへデプロイする

5. 更新とロールバック

6. カナリアリリースとタグ付きURL

7. オートスケールを観察する

8. ログとメトリクスをのぞく

9. 締め: Dockerfileすら書かないデプロイ

## 発展編(3時間版)

10. 発展編

10-1. Pub/Subとつなぐ

10-2. WebSocketチャット

10-3. Cloud Run Jobs

## おわりに

99. 後片付け

# AWSエンジニアのための Cloud Run ハンズオン

AWS を実務で使っているエンジニアに向けた、Google Cloud / Cloud Run のハンズオン教材です。

## この教材のゴール

1. **Cloud Run を通して Google Cloud の良さを知る** — 「デプロイしたら HTTPS の URL が返ってくる」体験から、Google Cloud の SaaS 的なアプローチを体感する
2. **AWS との違いを知る** — 単なるサービス名の読み替えではなく、思想の違いを理解する
3. **別のクラウドの目線を持ち帰る** — 普段 AWS で組んでいる構成を「Google Cloud ならどう組むか」で考えられるようになる

## 対象者

- クラウドを実務で利用したことがある(AWS がメイン)
- `docker build` / `docker run` を打ったことがある、もしくは概念は知っている
- Google Cloud はほぼ触ったことがなくて OK
- サンプルアプリは TypeScript + [Hono](#) 製ですが、書き換えるのは定数2行だけなので TypeScript の経験は不要です

## 進め方

前半(1〜3章)は座学パートの内容をそのまま収録しています。

ただし2章には Cloud Shell 上で Docker イメージを実際に作って動かすハンズオンも含まれます。

イベントではスライドで進行しますが、この GitBook 単体でも最初から最後まで完結するように書いてあります。

後半(4章〜)はブラウザ(Cloud Shell エディタと Google Cloud コンソール)だけで完結するハンズオンです。手元へのインストールは不要です。

## タイムテーブル

### 2時間版

| 時間          | 内容                                                              | 章    |
|-------------|-----------------------------------------------------------------|------|
| 0:00 - 0:10 | オープニング・ <a href="#">事前準備</a> の確認                                | 0    |
| 0:10 - 0:25 | 座学: <a href="#">AWS と Google Cloud の考え方の違い</a>                  | 1    |
| 0:25 - 0:40 | 座学: <a href="#">Docker のおさらい</a> ・ <a href="#">Cloud Run とは</a> | 2, 3 |
| 0:40 - 0:55 | ハンズオン: <a href="#">コンテナを作って動かす</a>                              | 2    |
| 0:55 - 1:15 | ハンズオン: <a href="#">Artifact Registry と Cloud Run へのデプロイ</a>     | 4    |
| 1:15 - 1:30 | ハンズオン: <a href="#">更新とロールバック</a>                                | 5    |

| 時間          | 内容                                                                          | 章    |
|-------------|-----------------------------------------------------------------------------|------|
| 1:30 - 1:45 | ハンズオン: <a href="#">カナリアリリースとタグ付きURL</a>                                     | 6    |
| 1:45 - 1:55 | ハンズオン: <a href="#">オートスケールを観察する</a>                                         | 7    |
| 1:55 - 2:00 | <a href="#">ログをのぞく</a> ・ <a href="#">締め: ソースデプロイ</a> ・ <a href="#">後片付け</a> | 8, 9 |

**講師向けペース設計メモ:** デプロイ待ちやアカウントトラブルで数分の遅れは必ず発生します。**6章(カナリアリリース)までを必達ライン**とし、押している場合は 7〜9章を講師の画面共有デモに切り替えてください。8〜9章は「見せる」だけでも学習目標は達成できます。詰まった参加者には[復旧ブロック](#)を案内してください。

**7章のコールドスタート観察は、直前の負荷試験でインスタンスが温まっているため多くの場合10分では体感できません。** Cloud Run は最大15分インスタンスをアイドル保持するためです。差が出なくても失敗ではないので、概念の説明を優先して先へ進んでください。

### 3時間版(2時間版に追加)

| 時間   | 内容                                          | 章  |
|------|---------------------------------------------|----|
| +20分 | ハンズオン: <a href="#">Pub/Sub とつなぐ</a>         | 10 |
| +10分 | デモ: <a href="#">WebSocket チャット</a>          | 10 |
| +10分 | デモ or ハンズオン: <a href="#">Cloud Run Jobs</a> | 10 |
| +20分 | 各章の深掘り・質疑・バッファ                              | -  |

## かかる費用

Cloud Run・Artifact Registry とともに無料枠が大きく、このハンズオンの範囲であればほぼ無料枠に収まります(数円〜数十円程度)。

心配な場合は最後の[後片付け](#)を必ず実施するか、ハンズオン専用プロジェクトを作って終了後にプロジェクトごと削除してください。

## この教材を手元で表示する

[HonKit](#)(GitBook 互換)でビルドできます。

```
npm install
npm run serve # http://localhost:4000
```

## PDF で読む・配布する

全章を1冊にまとめた [handson-cloudrun.pdf](#)(A4)を同梱しています。  
当日ネットワークが不安定な場合の保険や、事前配布に使ってください。

教材を更新したあとは以下で再生成できます([Playwright](#) と Chromium が必要です)。

```
npm run pdf
```

## 当日用サポートアプリ

[support/](#) に、この GitBook を iframe 表示しつつ「チャット・進捗共有・ヘルプ要請」ができるリアルタイムのサポートアプリがあります(TypeScript + Hono + WebSocket 製で、それ自体を Cloud Run で動かします)。イベントで使う場合は [support/README.md](#) を参照してください。GitBook 単体での利用には不要です。

## 関連リンク

- [Docker 入門ハンズオン\(introduction-docker\)](#) — Docker をより深く学びたい人向け
- [クラウドを今から学ぶには](#) — 非機能要件・オートスケーリング周りの背景

## 0. 事前準備

ハンズオン当日までに以下を済ませておいてください。

所要時間は**10分程度**ですが、アカウント作成と課金有効化は当日に始めると本人確認等で詰まることがあり全体が遅れます。

当日にアカウントを作らず、必ず事前をお願いします。

### 用意するもの

- Google アカウント — 会社のGoogle Workspaceアカウントではなく、**個人アカウントを推奨**します。  
会社アカウントは、管理者設定(Google Admin コンソールの Cloud Shell 設定)によって Cloud Shell の利用が無効化されていたり、組織ポリシー(ドメイン制限共有)によって `--allow-unauthenticated` (全公開)がブロックされていたりすることがあり、当日その場では解決できません
- クレジットカード(課金の有効化に必要。ハンズオンの範囲はほぼ無料枠に収まります)
- Chrome などのモダンブラウザ — **シークレット(プライベート)モードは避けてください**。サードパーティ Cookieが無効だと Cloud Shell エディタが開けないことがあります

手元のPCへのインストールは**一切不要**です。

ハンズオンはすべてブラウザ(Cloud Shell エディタと Google Cloud コンソール)で完結します。

## 1. Google Cloud プロジェクトを作る

AWS と大きく違うポイントその1です。

AWS では「アカウント」が課金・リソースの分離単位でしたが、Google Cloud では1つのアカウント(組織)の下に**プロジェクト**をいくつも作り、それが分離単位になります。

AWS のマルチアカウント運用(Organizations)でやっていたことを、Google Cloud はプロジェクトで軽量にやるイメージです。

- [Google Cloud コンソール](#)にログイン
- 初めての場合は無料トライアル(90日 / \$300 クレジット)の案内に従う
- 画面上部のプロジェクトセレクトから「新しいプロジェクト」を作成
  - プロジェクト名: `cloudrun-handson` など(IDは自動でユニークになります)
- 課金が有効になっていることを確認([課金ページ](#))

**ハンズオン専用プロジェクトを推奨**します。終わったらプロジェクトごと削除すれば、消し忘れによる課金の心配がありません。

## 2. Cloud Shell エディタを開く

[shell.cloud.google.com](https://shell.cloud.google.com) を開くか、コンソール右上のターミナルアイコンから Cloud Shell を起動し、「エディタを開く」をクリックします。

Cloud Shell は Google Cloud が無料で使える開発環境で、AWS の CloudShell に相当します。今日必要なものは最初から揃っています。

- ブラウザで動くコードエディタ (Cloud Shell エディタ)
- **Docker** (イメージのビルドと実行がその場でできる。今回のハンズオンの鍵)
- `gcloud` CLI (認証済み)
- 5GB の永続ホームディレクトリ (永続するのは `$HOME` だけ。それ以外への変更はセッション終了で失われます)

AWS の CloudShell にも Docker と `edit` コマンドのエディタがあります (2026年8月時点)。ただし永続ストレージは1GBで、Docker が使えるリージョンにも制限があります。「ブラウザだけでビルドからデプロイまで完走する」という今日の進め方は、5GBの `$HOME` と最初から使える Docker に支えられています。

**Cloud Shell を普段からよく使っている人へ:** Cloud Shell には週あたりの利用時間クォータ (デフォルト50時間) があり、使い切るとリセット時刻まで一切使えません。当日その場での回避策がほぼないので、ターミナルの [セッション情報] → [使用量の割り当て] で、**残りが4時間以上あること**を事前に確認してください (残り時間とリセット日時がダイアログに表示されます)。

### 3. プロジェクトの設定とAPIの有効化

Cloud Shell のターミナルで以下を実行します。

`YOUR_PROJECT_ID` は自分のプロジェクトIDに置き換えてください。

```
gcloud config set project YOUR_PROJECT_ID
```

続けて、ハンズオンで使うAPIを有効化します (数分かかることがあるので事前にやっておくのがおすすめです)。

```
gcloud services enable \  
  run.googleapis.com \  
  artifactregistry.googleapis.com \  
  cloudbuild.googleapis.com \  
  pubsub.googleapis.com \  
  cloudscheduler.googleapis.com
```

**AWSとの違い:** Google Cloud では各サービスの API を明示的に有効化してから使います。AWS のようにすべてのサービスが最初から呼べる状態ではなく、プロジェクトごとに使うサービスをオプトインする思想です。

### 4. 動作確認

```
gcloud config get-value project
```

プロジェクトIDが表示され、`docker version` がエラーにならないければ準備完了です。

## トラブルシューティング

- `gcloud services enable` で課金エラーが出る — プロジェクトに課金アカウントが紐付いていません。[課金ページ](#)から紐付けてください。
- Cloud Shell エディタが開かない・真っ白になる — シークレットモードやサードパーティCookieのブロックが原因のことが多いです。通常モードのブラウザで開き直すか、エディタを新しいウィンドウで開いてください。
- `--allow-unauthenticated` が権限エラーで失敗する — 会社アカウントの組織ポリシー(ドメイン制限共有)が原因の可能性が高いです。個人アカウント+個人プロジェクトに切り替えてください。
- IAM 権限を付与した直後に 403 が返る — IAM の変更の反映は通常2分程度、場合によっては7分以上かかります。数分待ってからリトライしてください。

## 復旧ブロック(困ったらここ)

Cloud Shell が切断された・タブを閉じてしまった・環境変数が消えた——そんなときは、**どの章にいても**以下を実行すれば作業状態を復元できます。

ファイルは `$HOME` ( `~/cloudrun-handson/` )に置くので消えずに残っており、失われるのは `export` した環境変数だけです。

```
cd ~/cloudrun-handson/app

export PROJECT_ID=$(gcloud config get-value project)
export REGION=asia-northeast1
export REPO=handson
export IMAGE=${REGION}-docker.pkg.dev/${PROJECT_ID}/${REPO}/app
```

`echo ${IMAGE}` を実行して `asia-northeast1-docker.pkg.dev/<あなたのプロジェクトID>/handson/app` のように表示されれば復元できています。

`-docker.pkg.dev//` のように途中が空になっていたら、`gcloud config set project YOUR_PROJECT_ID` からやり直してください。

## 途中で分からなくなったら

このハンズオンは git を使いません。

ファイルはエディタで手作りするので、**手元に「元に戻す」ためのリポジトリはありません。**

その代わりに、詰まったときは次の順番で復帰してください。

1. **その手順の直後にある吹き出しを読む。** 4章以降の主要な手順の末尾には「成功していれば」(そこまでで何が表示されていれば正解か)と「詰まったら」(よくあるエラーの原因と、そのままコピーして流せる復旧コマンド)が付いています。まずここを見るのが最短です。



2. **環境変数を疑う。** コマンドが `--region=` や `-docker.pkg.dev//` のように途中が空で失敗する場合は、Cloud Shell の再接続で環境変数が消えています。上の復旧ブロックを流し直してください。
3. **同じコマンドを、そのまま再実行する。** この教材のコマンドは、何度実行しても同じ結果になるように作っています (`gcloud run deploy` は新しいリビジョンを作るだけ、`ALREADY_EXISTS` は「すでにある」という意味なのでそのまま次へ進んで構いません)。
4. **章の頭からやり直す。** それでも状態が分からなくなったら、その章の最初の手順から順にコピーし直すのが確実です。各章は前章の完了状態を前提にしているので、「詰まったら」の吹き出しに書かれた前提(例: 4章の「0. 環境変数の準備」)を先に満たしてください。
5. **講師の画面に合流する。** 発展編(10章)のように自分の環境でなくても学べる節は、講師が映しているURLを見るだけで先へ進んで構いません。時間内に本編を終えることを優先してください。

# 1. AWSとGoogle Cloudの考え方の違い

## ビルディングブロック vs SaaS的アプローチ

AWS の思想は**ビルディングブロック**です。

VPC・サブネット・セキュリティグループ・IAMロール・ALB・ターゲットグループ……小さな部品を積み上げて、自分のアーキテクチャを組み立てます。

自由度が高い一方で、「Webアプリを1つ公開する」だけでも組み立てる部品の数は多くなります。

Google Cloud のマネージドサービスは、どちらかというと **SaaS 的なアプローチ**です。

「Webアプリを公開したい」という目的に対して、統合済みのサービスが1つ用意されていて、デフォルトで実用的な設定になっています。

部品を組む代わりに、完成品の設定を必要な分だけ調整します。

この違いが一番わかりやすいのが、今回扱う Cloud Run です。

まずは「コンテナを1つ、HTTPSで公開するまで」に必要なものを並べて見比べてみましょう。

### 例: コンテナを1つ、HTTPSで公開するまで

|         | AWS (ECS on Fargate + ALB)   | Google Cloud (Cloud Run)             |
|---------|------------------------------|--------------------------------------|
| ネットワーク  | VPC・サブネット・SG を用意             | 不要(必要なら後から VPC 接続)                   |
| 負荷分散    | ALB + ターゲットグループ + リスナー       | 不要(組み込み)                             |
| TLS証明書  | ACM で発行し ALB に紐付け            | 不要( *.run.app のHTTPS URLが自動発行)       |
| オートスケール | Application Auto Scaling を設定 | デフォルトで有効(0台~既定100台)                  |
| ログ      | awslogs ドライバや FireLens を設定   | 不要(stdout が自動で Cloud Logging へ)      |
| デプロイ    | タスク定義 + サービス更新               | <code>gcloud run deploy</code> 1コマンド |

どちらが優れているという話ではありません。

細かく制御したいなら AWS 的なアプローチが強く、素早く価値を出したいなら Google Cloud 的なアプローチが強い。

両方の目線を持っていると、状況に応じて最適な選択ができる——それが今日のゴールです。

**[要作図] 図1: 消える意思決定の数**

- **目的:** 教材全体の主題である「ビルディングブロック vs SaaS的アプローチ」を、部品の個数の差として一目で見せる。この図がこの教材でいちばん重要
- **左(AWS):** VPC → サブネット → セキュリティグループ → ECS クラスタ → タスク定義 → Fargate → ALB → リスナー → ターゲットグループ → ACM → Application Auto Scaling を、線でつないだ構成図として描く。**箱の多さそのものがメッセージ**
- **右(Cloud Run):** 箱は「Cloud Run サービス」1つだけ。そこから \*.run.app の HTTPS URL が出ている。左で描いた箱のうち消えたものを薄いグレーの点線で重ねて「プラットフォーム側に移った」と示すと対比が効く

- **注意:** 「Google Cloud のほうが優れている」と読ませない。「自由度をプラットフォームへ渡した結果」という趣旨の一文を**画像の中**に入れるとトレードオフとして読める(Markdown 側にキャプション文は置かない)
- **完成後の扱い:** 01\_aws\_and\_googlecloud/imgs/aws-vs-cloudrun-building-blocks.png として保存し、**見出しの直下**に **![AWSとCloud Runで必要になる構成要素の比較](imgs/aws-vs-cloudrun-building-blocks.png)** として差し込む(見出し → 画像 → 本文の順。キャプション文は付けない)
- **依存:** 8章の図8 も同じ左右配置(左=AWS、右=Cloud Run)と配色を使います。**図1 の左右の配置と配色を先に確定させてください**

## アカウント構造の違い

| 概念       | AWS                            | Google Cloud                                  |
|----------|--------------------------------|-----------------------------------------------|
| 分離の単位    | アカウント(Organizations の OU で階層化) | <b>プロジェクト</b> (組織 > フォルダ > プロジェクトの階層。フォルダは任意) |
| リージョンの扱い | コンソールでリージョンを切り替える              | リソース作成時に指定(コンソールは全リージョン横断)                    |
| 権限の主体    | IAMユーザー / ロール                  | Google アカウント / <b>サービスアカウント</b>               |
| API      | 常に有効                           | プロジェクトごとに <b>明示的に有効化</b>                      |

特に「プロジェクト」は Google Cloud を触るうえで最初に慣れておきたい概念です。

dev / staging / prod をプロジェクトで分ける、実験用に使い捨てプロジェクトを作る、といった運用が気軽にできます。

## サービス対応表

ハンズオン中に「AWSでいうと何?」と思ったら、ここに戻ってきましょう。

### 今日使うサービス

| Google Cloud                   | AWSでいうと                              | 補足                                                          |
|--------------------------------|--------------------------------------|-------------------------------------------------------------|
| <b>Cloud Run</b>               | App Runner + ECS on Fargate + Lambda | どれとも微妙に違う。次章で詳しく                                            |
| <b>Artifact Registry (GAR)</b> | ECR                                  | コンテナ以外(npm, Maven等)も置ける                                     |
| <b>Cloud Shell</b>             | CloudShell                           | エディタ付き・Docker が動く(AWS CloudShell も同様。ただし Docker は対応リージョン限定) |
| <b>Cloud Build</b>             | CodeBuild                            | ソースデプロイの裏側で動く                                               |
| <b>Cloud Logging</b>           | CloudWatch Logs                      | 設定不要で stdout を収集                                            |
| <b>Cloud Monitoring</b>        | CloudWatch                           | メトリクスはデフォルトで収集済み                                            |
| <b>Pub/Sub</b>                 | SNS + SQS                            | 1サービスで pub/sub もキューも担う                                      |

## 今日は使わないが対応を知っておくと便利なサービス

| Google Cloud                           | AWSでいうと                  | 補足                                              |
|----------------------------------------|--------------------------|-------------------------------------------------|
| Compute Engine                         | EC2                      |                                                 |
| GKE                                    | EKS                      | Kubernetes 発祥の地だけあり完成度が高い                       |
| Cloud Run functions(旧 Cloud Functions) | Lambda                   | 現在は Cloud Run 基盤に統合され、名称も Cloud Run functions へ |
| Cloud Storage                          | S3                       |                                                 |
| Cloud SQL                              | RDS                      |                                                 |
| Spanner                                | Aurora DSQL(2025年5月 GA)  | グローバル分散RDB。強整合な分散SQLという点で近い                     |
| BigQuery                               | Redshift + Athena        | Google Cloud 最大の看板サービス                          |
| Eventarc                               | EventBridge              | 各サービスのイベントを Cloud Run へ配送                       |
| Cloud Tasks                            | SQS(遅延キュー用途)             | HTTPターゲットに直接push                                |
| Cloud Scheduler                        | EventBridge Scheduler    | cron                                            |
| Secret Manager                         | Secrets Manager          |                                                 |
| Cloud Load Balancing                   | ALB/NLB + CloudFront の一部 | グローバル単一エニーキャストIP                                |
| IAM サービスアカウント                          | IAM ロール                  | 「アカウント」だが実体はロールに近い                              |

## まとめ

- AWS は部品を組み立てる。Google Cloud は完成品を調整する
- 分離単位は「アカウント」ではなく「プロジェクト」
- 対応表は読み替えの入口。ただし思想が違うので1対1にはならない——それを体感するのがこの後のハンズオン

## 2. Dockerのおさらいとコンテナ起動

この章では Docker の要点をおさらいしたあと、実際に Web サーバーのコンテナイメージを作って・動かして・ブラウザで見るところまでやってみましょう。

ここで作ったイメージを、次章以降で Cloud Run にデプロイしていきます。

Docker をしっかり学びたい人は [introduction-docker](#) にまともっています。今日は Cloud Run に必要な分だけ、駆け足で。

### おさらい: 3つの登場人物

| 用語         | 一言でいうと                       | AWSでの馴染み             |
|------------|------------------------------|----------------------|
| Dockerfile | イメージの設計図(テキストファイル)           | CodeBuild でビルドしていたアレ |
| イメージ       | アプリ+依存関係+OSライブラリを固めたスナップショット | ECR に push していたアレ    |
| コンテナ       | イメージを実行したプロセス                | ECS タスクの中で動いていたアレ    |

ポイントは1つだけです: **イメージは不変(immutable)**。  
「環境ごと固めて配る」からこそ、ローカルでも Cloud Run でも ECS でも同じように動きます。  
この不変性が、後でやるロールバックやカナリアリリースの土台になります。

### ハンズオン: Webサーバーのイメージを作る

アプリは TypeScript + [Hono](#) で書きます。  
Hono は Web 標準 API ベースの軽量な Web フレームワークです(Hono 自体は Cloudflare Workers や Deno などマルチランタイム対応ですが、今回は Node.js アダプタと Node.js API を使います)。  
実行には Node.js 24 の組み込み **type stripping** ——型注釈を剥がして実行する機能——を使い、この教材で使う範囲の TypeScript をビルドステップなしで動かします。  
ビルドを1段消すことで、今日の主役である Cloud Run に集中するためです。

type stripping は型注釈を空白に置き換えるだけで、型チェックは行いません(`tsc` の代替ではありません)。  
`tsconfig.json` も読まれないため、enum や parameter properties のように「変換が必要な構文」は使えません。この教材のコードはすべて対応範囲内です。

TypeScript に詳しくなくても大丈夫です。書き換えるのは定数2行だけで、あとはコピー&ペーストで進められます。

### 1. 作業ディレクトリとファイルの作成

Cloud Shell エディタのターミナルで作業ディレクトリを作ってみましょう。

```
mkdir -p ~/cloudrun-handson/app/src
cd ~/cloudrun-handson/app
```

エディタで以下の4ファイルを作成してみましょう(コピー&ペーストでOK)。  
このリポジトリの [code/app/](#) にも同じものがあります。

`package.json` — 依存関係は Hono 本体と Node.js アダプタの2つだけです。

```
{
  "name": "handson-app",
  "private": true,
  "type": "module",
  "engines": {
    "node": "24.x"
  },
  "scripts": {
    "start": "node src/index.ts"
  },
  "dependencies": {
    "@hono/node-server": "1.19.17",
    "hono": "4.13.2"
  }
}
```

`src/index.ts` — 小さなWebサーバーです。アクセスすると「メッセージ・リビジョン名・インスタンスID」を表示します。

```
import { serve } from "@hono/node-server";
import { Hono } from "hono";
import crypto from "node:crypto";

// =====
// ハンズオンで書き換えるのはこの2行です
// =====

const MESSAGE = "Hello, Cloud Run!";
const BG_COLOR = "#4285F4"; // v1: 青 / v2: "#EA4335" 赤 / v3: "#34A853" 緑

// コンテナ(インスタンス)が起動したタイミングで一意的なIDを生成する。
// オートスケールで何台に増えたかを見分けるために使う。
const INSTANCE_ID = crypto.randomUUID().slice(0, 8);

// stdout に1行JSONを吐くと Cloud Logging が構造化ログとして解釈する
const log = (severity: string, message: string, extra: Record<string, unknown> = {}) => {
  console.log(JSON.stringify({ severity, message, ...extra }));
};
```

```

const app = new Hono();

app.get("/", (c) => {
  log("INFO", "index accessed", { instance: INSTANCE_ID });
  // K_SERVICE / K_REVISION は Cloud Run が自動で注入する環境変数

  const service = process.env.K_SERVICE ?? "local";
  const revision = process.env.K_REVISION ?? "local";

  return c.html(`<!DOCTYPE html>

<html lang="ja">
<head>
  <meta charset="utf-8">
  <meta name="viewport" content="width=device-width, initial-scale=1">
  <title>Cloud Run Handson</title>
  <style>
    body {
      margin: 0;
      display: flex;
      flex-direction: column;
      align-items: center;
      justify-content: center;
      min-height: 100vh;
      background: #333;          /* BG_COLOR を書き間違えても文字が読めるようにする保険 */
      background: ${BG_COLOR};
      color: #fff;
      font-family: sans-serif;
    }
    h1 { font-size: 3rem; margin: 0.5rem; }
    table { margin-top: 2rem; border-collapse: collapse; }
    td { padding: 0.3rem 1rem; border: 1px solid rgba(255,255,255,0.5); }
  </style>
</head>
<body>
  <h1>${MESSAGE}</h1>
  <table>
    <tr><td>Service</td><td>${service}</td></tr>
    <tr><td>Revision</td><td>${revision}</td></tr>
    <tr><td>Instance</td><td>${INSTANCE_ID}</td></tr>
  </table>
</body>
</html>`);
});

// スクリプトから叩きやすいJSON版。カナリアの割合確認などに使う

```

```

app.get("/api", (c) =>
  c.json({
    message: MESSAGE,
    revision: process.env.K_REVISION ?? "local",
    instance: INSTANCE_ID,
  }),
);

// 1秒かかる重い処理のふり。負荷試験でオートスケールを観察するために使う
app.get("/heavy", async (c) => {
  await new Promise((resolve) => setTimeout(resolve, 1000));
  return c.json({ instance: INSTANCE_ID });
});

// Pub/Sub push サブスクリプションの受け口(発展編で使用)
app.post("/pubsub", async (c) => {
  const envelope = await c.req.json().catch(() => ({}));
  // 外部から任意のJSONが飛んでくるため、文字列以外は空扱いにする
  const raw = envelope?.message?.data;
  const data = typeof raw === "string" ? raw : "";
  const text = data ? Buffer.from(data, "base64").toString("utf-8") : "(empty)";
  log("INFO", `Pub/Sub message received: ${text}`);
  return c.body(null, 204);
});

// 未捕捉の例外も1行JSONで出します。8章で severity フィルタを試す材料になります。
app.onError((err, c) => {
  log("ERROR", err.message, { stack: err.stack });
  return c.json({ error: "internal server error" }, 500);
});

// Cloud Run は環境変数 PORT でリスンすべきポートを渡してくる。
// `??` は空文字を拾わないため、`||` で「空文字・数値でない値」もまとめて弾く。
const port = Number(process.env.PORT) || 8080;
const server = serve({ fetch: app.fetch, port }, () => {
  log("INFO", `listening on port ${port}`);
});

// Cloud Run はインスタンス終了の10秒前に SIGTERM を送ります。
// 受け取ってから新規受付を止めることで、処理中のリクエストを取りこぼしません。
process.on("SIGTERM", () => {
  log("INFO", "SIGTERM received, shutting down");
});

```



```
server.close() => process.exit(0));
});
```

#### Dockerfile

```
FROM node:24-slim

WORKDIR /app

COPY package.json ./
RUN npm install

COPY . ./

# Cloud Run が環境変数 PORT を注入します(既定 8080)。
# 公式の container contract により、コンテナ側で PORT を設定してはいけません。
# ローカルの docker run では未設定になるため、アプリ側で 8080 にフォールバックしています。

# Node.js 24 の組み込み type stripping で TypeScript を直接実行する
# (型注釈を剥がすだけで、型チェックは行われない)
CMD ["node", "src/index.ts"]
```

`.dockerignore` — ローカルで `npm install` した場合に `node_modules` をイメージに混入させないためのファイルです。

```
node_modules
```

**Dockerfile を上から読んでみましょう。** ベースイメージ( `FROM` )に依存関係を重ね( `RUN npm install` )、コードを載せ( `COPY` )、起動コマンドを決める( `CMD` )。この積み重ねがそのままイメージのレイヤーになります。

`package.json` だけ先に `COPY` しているのは、コードを変更しても `npm install` のレイヤーキャッシュが効くようにするテクニックです(この後の章で効いてきます)。

1点だけ Cloud Run 固有の約束があります: **環境変数 `PORT` で渡されたポートを `listen` すること**。ECS でいうタスク定義のポートマッピングにあたる取り決めが、この環境変数1つに集約されています。

## 2. イメージをビルドする

```
docker build -t handson-app:v1 .
```

手元に Node.js がなくても( `npm install` を一度も打っていなくても)ビルドできることに注目してみましょう。依存解決も実行環境も、すべてイメージの中で完結しています。

`docker images` で `handson-app` ができていることを確認してみましょう。

### 3. コンテナを起動する

```
docker run --rm -p 8080:8080 handson-app:v1
```

### 4. ブラウザで見る

Cloud Shell の右上にある[ウェブでプレビュー]ボタン(ウィンドウの中に目が描かれたアイコン)→[ポート 8080 でプレビュー]をクリックします。

青い画面に「Hello, Cloud Run!」と表示されれば成功です。

Revision と Service が `local` になっていることも確認してみましょう——Cloud Run にデプロイすると、ここが自動で埋まります。

確認できたらターミナルで `Ctrl+C` を押してコンテナを止めます。

### 5. (余裕があれば)コンテナの中に入ってみる

```
docker run --rm -it handson-app:v1 bash

ls          # 自分の書いたコードと node_modules が /app に入っている
node -v     # イメージに焼き込まれた Node.js 24
exit
```

## まとめ

- Dockerfile → イメージ → コンテナ、の流れを一周した
- イメージは不変。だから「どこでも同じに動く」し「前のバージョンに戻せる」
- Cloud Run との約束は「環境変数 `PORT` を listen する」だけ

今、あなたの手元(Cloud Shell)には動くイメージがあります。

次章で Cloud Run の仕組みを知り、4章でこれをそのままクラウドに載せます。

### 3. Cloud Runとは

Cloud Run は「コンテナを渡すと、HTTPS の URL を返してくれる」フルマネージドなコンテナ実行基盤です。

- サーバー(VM・クラスタ)の管理は不要
- リクエストに応じて **0台から自動でスケール**し、使った分だけ課金
- デプロイの単位は普通のコンテナイメージ。ランタイムの縛りなし

#### AWSでいうと何？

App Runner・Fargate・Lambda のどれかに対応付けたくてなりますが、どれとも微妙に違います。

この「微妙に違う」がそのまま Cloud Run の魅力なので、表で整理してみましょう(2026年8月時点)。

|                          | Lambda(標準)       | ECS on Fargate + ALB | App Runner              | Cloud Run                                 |
|--------------------------|------------------|----------------------|-------------------------|-------------------------------------------|
| デプロイ単位                   | 関数 / イメージ        | イメージ                 | イメージ / ソース              | イメージ / ソース                                |
| 実行モデル                    | 1リクエスト=1実行環境 ※1  | 常駐                   | 常駐                      | <b>1インスタンスで複数リクエストを並行処理</b> (既定80・最大1000) |
| スケールtoゼロ                 | ○                | ×                    | ×(最低1台のメモリ課金)           | ○                                         |
| 課金                       | リクエスト処理時間        | 常時(起動時間)             | プロビジョンドメモリ(常時)+処理中のvCPU | <b>リクエスト単位 / 常時 を選択可</b> ※2               |
| 実行時間上限                   | 15分              | なし                   | <b>120秒</b> (リクエストあたり)  | 60分(リクエストあたり)                             |
| HTTPS URL                | ○(Function URLs) | 要 ALB + ACM          | ○                       | ○( <b>自動発行</b> )                          |
| WebSocket / gRPC / HTTP2 | 苦手(要別サービス)       | ○(要ALB/NLB設定)        | 実質不可(120秒上限)            | ○                                         |
| VPC                      | 内で動く             | 内で動く                 | 外(接続可)                  | <b>外(接続可)</b>                             |

※1 2025年11月に登場した **Lambda Managed Instances** では、1つの実行環境で複数リクエストの並行処理が可能になりました。「普通のWebサーバー+インスタンス内並行処理」という Cloud Run が以前から持つモデルへ、AWS 側も歩み寄ってきた、と見ると両クラウドの設計思想の変化が見えて面白いところです。

※2 正式には **request-based billing**(リクエスト処理中を中心に課金)と **instance-based billing**(インスタンス起動中は常時課金)の2モデルから選びます。詳細は後述。

押さえておきたいポイントは3つです。

1. **Lambda の手軽さ × コンテナの自由度**。スケールtoゼロ・従量課金でありながら、中身はただのWebサーバー。Lambda 特有のハンドラ関数やランタイム制約がなく、手元で `docker run` できるものがそのまま動きます。
2. **1インスタンスが複数リクエストを同時に捌く**。標準の Lambda は1リクエスト1環境なのでインスタンス数が爆発しがちですが、Cloud Run は「並行数(concurrency)」の分だけ1台で受けます。Webサーバーの

常識がそのまま通用します。

3. **VPCが前提にない**。AWS では最初に VPC を作りますが、Cloud Run はデフォルトで VPC の外。DB接続などで必要になったときだけ VPC に「つなぎに行く」発想です。

## 3つの実行モデル

Cloud Run には現在、ワークロードの形に合わせた**3つの実行モデル**があります。

今日のハンズオンの主役はサービスですが、この3分類を頭に入れておくと「Cloud Run ≡ App Runner」という誤解をせずに済みます。

| 実行モデル                 | 向いているもの                        | AWSでいうと                |
|-----------------------|--------------------------------|------------------------|
| サービス (Service)        | HTTPリクエスト / イベント駆動             | App Runner, Lambda+ALB |
| ジョブ (Job)             | 実行して終わるバッチ処理(発展編10-3)          | ECS RunTask, AWS Batch |
| ワーカープール (Worker pool) | 常駐してキューをpullし続ける処理(2026年4月 GA) | SQSをポーリングするECS常駐ワーカー   |

Kafka コンシューマや Pub/Sub の pull 型ワーカーのような「リクエスト起点でない常駐処理」も、Worker pools の登場で Cloud Run に乗るようになりました。

同じイメージ・同じ開発体験のまま実行モデルだけ選び替えられるのが、このプラットフォームの設計の一貫性です。

### [要作図] 図2: 3つの実行モデル

- **目的:** 「Cloud Run ≡ App Runner」という誤解を壊す。同じコンテナイメージが中央にあり、そこから3方向に分岐するという構図にすることが要点
- **中央:** 「同じコンテナイメージ」の箱を1つ置く
- **3方向の分岐:** それぞれ「何が起動のきっかけか」→「どう終わるか」を1組で描く
  - サービス: HTTPリクエスト / イベント → 常に待ち受け(URLを持つ)
  - ジョブ: 実行命令(手動 / スケジュール) → プロセスが exit したら完了
  - ワーカープール: キューを自分で pull → 常駐しつづける(URLを持たない)
- **補足:** ワーカープールに「URLなし」を明示すると、サービスとの違いが伝わる。AWS 対応(App Runner / ECS RunTask / SQSをポーリングするECS常駐ワーカー)を各分岐の脇に小さく添えてもよい
- **完成後の扱い:** 03\_cloudrun/imgs/three-execution-models.png として保存し、見出しの直下に `![同じコンテナイメージから分岐する3つの実行モデル](imgs/three-execution-models.png)` として差し込む(見出し → 画像 → 本文の順。キャプション文は付けない)

## Cloud Run の構成要素

ハンズオンで触る概念は3つだけです。

#### サービス (Service)

└── リビジョン **rev-00003** ← トラフィック 100%  
└── リビジョン **rev-00002**  
└── リビジョン **rev-00001**

- **サービス**: URL を持つ論理単位。ECS でいう「サービス+ALB+ターゲットグループ」を1つにしたもの
- **リビジョン**: デプロイのたびに作られる**不変のスナップショット**(イメージ+環境変数+CPU/メモリ設定のセット)。過去のリビジョンは残り続ける
- **トラフィック分割**: どのリビジョンに何%流すかをサービスが制御。ロールバックもカナリアもこの仕組みの上に乗っている

「リビジョンが不変で、トラフィックを好きに振り分けられる」——2章でおさらいしたイメージの不変性が、プラットフォームの機能にまで貫かれています。

ここが Cloud Run の設計の美しさで、5章・6章で実際に体験していきましょう。

## 料金感

課金モデルは2種類から選びます(サービス作成後も切替可)。

- **request-based billing(デフォルト)**: リクエスト処理中を中心に CPU・メモリが課金され、スケールtoゼロ時はインスタンス課金がなくなる。起動・終了処理や min-instances のアイドル時間など例外はある
- **instance-based billing**: インスタンス起動中は常時課金。単価はrequest-basedより安く、常時処理があるワークロード向け

無料枠も課金モデルごとにあります(2026年8月時点。単価・無料枠は改定されるので[公式の料金ページ](#)が正)。

- request-based: 月あたり vCPU 18万秒 / メモリ 36万GiB秒 / リクエスト200万件
- instance-based: 月あたり vCPU 24万秒 / メモリ 45万GiB秒

個人開発や社内ツールなら実質無料で運用できることが多く、「とりあえず公開しておく」が気軽にできます。

## 制約・向かないもの

公平のために、向かないケースも知っておきましょう。

- 常時接続の重いステートフルワークロード(ゲームサーバー等)→ GKE / GCE
- リクエスト起点でない常駐pull処理 → 先述の **Worker pools**(それでも合わなければ GKE)
- 起動に数分かかる巨大アプリ → コールドスタートが辛い(7章で対策も扱います)
- スペック上限の目安: 通常のCPUサービスで **8 vCPU / 32GiB メモリ** (GPU構成は別枠)

## まとめ

- Cloud Run = コンテナを渡すと HTTPS URL が返ってくる。Lambda の運用感覚 × コンテナの自由度
- 実行モデルは「サービス・ジョブ・ワーカープール」の3つ。今日の主役はサービスで、概念は「サービス・リビジョン・トラフィック分割」の3つだけ

- 座学はここまで。ここからは全部手を動かします

## 4. Cloud Runへデプロイする

2章で作ったイメージを Artifact Registry(GAR)に push し、Cloud Run にデプロイして、世界中からアクセスできる HTTPS URL を手に入れます。

### 0. 環境変数の準備

この先の章でも使うので、まとめて設定しておきます(Cloud Shell が切断された場合はここから再実行してください)。

```
export PROJECT_ID=$(gcloud config get-value project)
export REGION=asia-northeast1 # 東京リージョン
export REPO=handson
export IMAGE=${REGION}-docker.pkg.dev/${PROJECT_ID}/${REPO}/app
```

`asia-northeast1` = 東京です。AWS の `ap-northeast-1` と対応が覚えやすいですね。

### 1. Artifact Registry にリポジトリを作る

ECR と同じく、イメージの置き場をまず作ります。

```
gcloud artifacts repositories create ${REPO} \
  --repository-format=docker \
  --location=${REGION} \
  --description="Cloud Run handson"
```

docker コマンドが GAR に push できるよう、認証ヘルパーを設定します(ECR の `aws ecr get-login-password` に相当。こちらは一度設定すれば、push のたびにトークンを取り直す必要はありません)。

```
gcloud auth configure-docker ${REGION}-docker.pkg.dev
```

**成功していれば:** リポジトリ作成が `Created repository [handson].` で終わり、`gcloud artifacts repositories list --location ${REGION}` に `handson` が1行表示されます。認証ヘルパーの設定は `Docker configuration file updated.` で終わります。すでに設定済みの環境では `gcloud credential helpers already registered correctly.` と表示されますが、こちらも成功です。詰まったら: `ALREADY_EXISTS` は作成済みという意味なので、そのまま次へ進んで構いません。`PERMISSION_DENIED` や API 無効のエラーが出た場合は `gcloud services enable artifactregistry.googleapis.com run.googleapis.com` を実行してから作成コマンドを再実行してください。`${REPO}` や `${REGION}` が空文字で展開されている(コマンドが `create --location=` のように見える)場合は、Cloud Shell の再接続で環境変数が消えています。「0. 環境変数の準備」を再実行してください。

## 2. イメージにタグを付けて push する

GAR のイメージパスは リージョン-docker.pkg.dev/プロジェクト/リポジトリ/イメージ名:タグ という形式です。2章で作ったイメージにこのパスでタグを付け直して push します。

```
cd ~/cloudrun-handson/app
docker tag handson-app:v1 ${IMAGE}:v1
docker push ${IMAGE}:v1
```

push できたか確認してみましょう。

```
gcloud artifacts docker images list ${REGION}-docker.pkg.dev/${PROJECT_ID}/${REPO}
```

[コンソールの Artifact Registry](#) からも見えます。

**成功していれば:** `docker push` の最後が `v1: digest: sha256:... size: ...` で終わり、`gcloud artifacts docker images list` の出力に `.../handson/app` の行が1つ表示されます。 **詰まったら:** `An image does not exist locally with the tag: handson-app` と出た場合は2章のイメージが手元にありません。 `cd ~/cloudrun-handson/app && docker build -t handson-app:v1 .` でビルドし直してから、タグ付けと push をやり直してください(手元のイメージ一覧は `docker images` で確認できます)。 `denied` や `unauthorized` が出る場合は `gcloud auth configure-docker ${REGION}-docker.pkg.dev` を実行してから `docker push ${IMAGE}:v1` を再実行します。 `echo ${IMAGE}` が空、または `-docker.pkg.dev//` のように途中が抜けている場合は「0. 環境変数の準備」を再実行してください。

## 3. Cloud Run にデプロイする

いよいよ本番です。

このコマンド1つで、ECS なら ALB・ターゲットグループ・ACM 証明書・サービス・タスク定義を組み立てていた作業がすべて終わります。

```
gcloud run deploy handson-app \
  --image ${IMAGE}:v1 \
  --region ${REGION} \
  --allow-unauthenticated
```

- `handson-app` がサービス名になります
- `--allow-unauthenticated` は「認証なしで公開」。デフォルトは IAM 認証必須(=閉じている)で、AWS と逆のデフォルトです

30秒ほどで完了し、`Service URL: https://handson-app-<プロジェクト番号>.asia-northeast1.run.app` のような URL が表示されます。

**成功していれば:** 出力の最後に `Service [handson-app] revision [handson-app-00001-xxx] has been deployed and is serving 100 percent of traffic.` と Service URL が表示されます。URL は サービス名-プロジェクト番号.リージョン.run.app という決まった形式です。あとから `gcloud run services describe handson-app --region ${REGION} --`



`format 'value(status.url)'` でいつでも取り直せますが、こちらは `handson-app-<ランダム文字列>-an.a.run.app` という古い形式の URL を返します。**どちらも同じサービスを指す有効な URL** なので、見た目が違っていても気にしないで大丈夫です(6章以降では `describe` で取得した URL をそのまま使います)。詰まったら: まず `gcloud run services list --region ${REGION}` でサービスが作られているか確認してください。作られていなければエラーの原因を切り分けます。`Image not found` や `manifest unknown` の場合は「2. イメージにタグを付けて push する」の push が完了していないので、`gcloud artifacts docker images list ${REGION}-docker.pkg.dev/${PROJECT_ID}/${REPO} --include-tags` を実行し、`TAGS` 列に `v1` が付いた行があるかを確認してください。`--region` や `--image` が空で怒られる場合は「0. 環境変数の準備」を再実行します。設定を間違えた場合も、同じ `gcloud run deploy` コマンドを何度でも実行し直して大丈夫です(新しいリビジョンが作られて上書きされます)。

## 4. アクセスして確認する

表示された URL をブラウザで開いてください。

2章で Cloud Shell の中で見たのと同じ青い画面が、今度は本物のインターネット越しに表示されます。

2章との違いを見てみましょう:

- `Service` が `handson-app` に、`Revision` が `handson-app-00001-xxx` になっている(Cloud Run が注入する環境変数 `K_SERVICE` / `K_REVISION` をアプリが表示している)
- URL が最初から **HTTPS**。証明書の発行も更新も何もしていない

コンソールの [Cloud Run のページ](#) も開いてみてください。

サービスの一覧、リビジョン、メトリクス、ログがすべて1画面に集約されています。

### [要作図] 図3: この章でやったことの流れ

- **目的:** 4章で打った3コマンドが、どこからどこへ何を運んだのかを1枚で振り返れるようにする。5章以降で何度も戻ってくる基準図になる
- **描く流れ:** 手元のコード(`~/cloudrun-handson/app`) → `docker build` でイメージ → `docker push` で Artifact Registry → `gcloud run deploy` で Cloud Run サービス → `*.run.app` の HTTPS URL
- **各ステップに添える情報:** そのステップで登場する Google Cloud のサービス名と、AWS での対応 (Artifact Registry ↔ ECR など)
- **補足:** Cloud Run の箱の中に「リビジョン 00001」を小さく描いておくと、5章のリビジョンの話に自然につながる
- **レイアウトの制約:** 9章のソースデプロイでは `docker build` と `docker push` の2ステップがプラットフォーム側へ移ります。9章の図3b と並べて差分が読めるように、箱の位置とレイアウトを固定してください
- **完成後の扱い:** `04_deploy/imgs/deploy-flow.png` として保存し、**見出しの直下に** `![4章でやったことの流れ]` (`imgs/deploy-flow.png`) として差し込む(見出し → 画像 → 本文の順。キャプション文は付けない)

## ふりかえり: 何をしなかったか

ここまでで「したこと」は リポジトリ作成 → push → deploy の3コマンドです。  
それより「しなかったこと」に注目してください。

- VPC・サブネット・セキュリティグループを作らなかった
- ロードバランサーもリスナーも作らなかった
- TLS 証明書を発行しなかった
- タスク定義(CPU/メモリ/ポート)を書かなかった ※デフォルト値で開始し、必要なら後から変える
- キャパシティ(台数)を決めなかった

1章で話した「ビルディングブロック vs SaaS的アプローチ」が、これで体感できたはずです。

## 5. 更新とロールバック

アプリを変更して2回目のデプロイを行い、「リビジョン」がどう積み重なるかを見ます。  
その後、本番障害を想定して30秒でロールバックします。

### 1. アプリを変更する (v2)

`src/index.ts` の上部にある2行を書き換えます。

```
const MESSAGE = "Hello, Cloud Run v2!";  
const BG_COLOR = "#EA4335"; // 赤
```

### 2. ビルドして push して deploy

2章・4章でやったことの繰り返しです。  
タグは `v2` にします。

```
cd ~/cloudrun-handson/app  
docker build -t ${IMAGE}:v2 .  
docker push ${IMAGE}:v2  
  
gcloud run deploy handson-app \  
  --image ${IMAGE}:v2 \  
  --region ${REGION}
```

2回目以降は `--allow-unauthenticated` などの設定を繰り返す必要はありません。サービスの設定は維持され、**変更したものの(イメージ)だけが新しいリビジョンとして記録されます。**

ブラウザをリロードしてください。

画面が赤くなり、Revision が `handson-app-00002-xxx` に変わっていれば成功です。

ダウンタイムなしで切り替わったことにも注目してください。

**成功していれば:** デプロイの出力に `revision [handson-app-00002-xxx] has been deployed and is serving 100 percent of traffic.` と表示され、`gcloud run revisions list --service handson-app --region ${REGION}` の行が2つになります。なお番号が `00002` にならないことがあります。採番はデプロイ回数と一致せず飛ぶことがあるので、**行が2つに増えていれば成功です**(リビジョンを見分けるのは末尾のランダム文字列です)。**詰まったら:** 画面が赤くならない場合、まずブラウザのスーパーリロード(Cmd+Shift+R / Ctrl+Shift+R)を試してください。それでも青いままなら `src/index.ts` の書き換えが保存されていない可能性があるので、ファイルを保存し直して `docker build` から再実行します。`docker build` が `no such file or directory` で失敗する場合は `cd ~/cloudrun-handson/app` を忘れています。`invalid reference format` や `-docker.pkg.dev//` のようなパスになる場合は Cloud Shell の再接続で環境変数が消えているので、4章の「0. 環境変数の準備」を再実行してください(`echo ${IMAGE}` で確認できます)。

### 3. リビジョンの一覧を見る

```
gcloud run revisions list --service handson-app --region ${REGION}
```

00001 (青/v1)と 00002 (赤/v2)の両方が残っています。

リビジョンは**イメージ+環境変数+リソース設定を固めた不変のスナップショット**で、デプロイのたびに積み重なっていきます。

**AWSとの比較:** ECS のタスク定義リビジョンに似ていますが、Cloud Run のリビジョンは「どこにトラフィックを流すか」の制御と一体化している点が違います。タスク定義+ALB加重ルーティング+デプロイ履歴が1つの概念になっているイメージです。

### 4. ロールバックする

ここで想定シナリオ: 「v2 をリリースしたらバグ報告が来た!すぐ戻したい!」

AWS ならどうしますか?

前のタスク定義を指定してサービス更新、デプロイが走るのを待つ——数分かかります。

Cloud Run では、**すでに存在する v1 のリビジョンにトラフィックを振り向けるだけです**。

新しいデプロイは走りません。

#### [要作図] 図4: ロールバックはトラフィックの向きを変えるだけ

- **目的:** 「リビジョンは不変で、動くのはトラフィックだけ」を理解させる。この章の核心
- **描き方:** 横に3コマ並べた時系列。各コマに「サービスURL」が1つあり、そこから下のリビジョン群へ矢印が伸びる構図にする
  1. v1 デプロイ直後 — リビジョン 00001 のみ、矢印 100%
  2. v2 デプロイ後 — 00001 と 00002 が**両方存在**し、矢印は 00002 へ 100%
  3. ロールバック後 — リビジョンは2つのまま、矢印だけ 00001 へ戻る
- **要点:** 3コマを通じて**リビジョンの箱は消えず増えるだけ**であることを見せる。動くのは矢印だけ。ここが AWS のローリングデプロイとの決定的な違い
- **注意:** 番号は 00001 / 00002 と書いてよいですが、実際の採番は連番にならず飛ぶことがあります(この章の「2. ビルドして push して deploy」と6章の「2. トラフィックを流さずにデプロイする」で触れています)。図では概念として扱ってください
- **完成後の扱い:** 05\_revision/imgs/rollback-traffic-switch.png として保存し、**見出しの直下に** **![ロールバックはトラフィックの向きを変えるだけ](imgs/rollback-traffic-switch.png)** として差し込む(見出し → 画像 → 本文の順。キャプション文は付けない)

まず v1 のリビジョン名を確認して:

```
gcloud run revisions list --service handson-app --region ${REGION}
```

トラフィックを 100% 戻します( `handson-app-00001-xxx` は自分のリビジョン名に置き換え):

```
gcloud run services update-traffic handson-app \  
  --region ${REGION} \  
  --to-revisions handson-app-00001-xxx=100
```

数秒待ってからブラウザをリロードしてください。

**青(v1)に戻ります。**

トラフィックの切り替えは瞬時ではないため、まだ赤のままなら少し待って再読み込みしてください。

コンソールでも同じことができます: [Cloud Run](#) → サービス → 「リビジョン」タブ → 対象リビジョンの右側にある省略記号アイコンから「トラフィックを管理」。

障害対応の現場では GUI でポチッと戻せるのは心強いです。

**成功していれば:** コマンドの出力に `100% handson-app-00001-xxx` のようなトラフィック割り当てが表示され、数秒後のリロードで画面が青(v1)に戻ります。割り当ての現状は `gcloud run services describe handson-app --region ${REGION}` の出力の Traffic 欄で確認できます。 **詰まったら:** `Revision 'handson-app-00001-xxx' does not exist` と出た場合は、リビジョン名をそのままコピーしてしまっています。 `gcloud run revisions list --service handson-app --region ${REGION} --format 'value(metadata.name)'` で実際の名前を取得し、`00001` を含む行の値に置き換えてください。まだ赤いままの場合は、トラフィックの切り替えは瞬時ではないので10~20秒待ってからスーパーリロードします。それでも変わらなければ、上の `describe` で Traffic 欄が意図した割り当てになっているかを確認してください。

## 5. 次章に備えて v2 に戻しておく

ロールバック体験が終わったので、最新リビジョン(v2)に戻しておきます。

```
gcloud run services update-traffic handson-app \  
  --region ${REGION} \  
  --to-latest
```

ブラウザで赤(v2)に戻ったことを確認してください。

**成功していれば:** Traffic の割り当てが `100% LATEST (currently handson-app-00002-xxx)` になり、リロードで赤(v2)が表示されます。 **次章はこの状態(最新リビジョンに100%)から始めるので、ここまでは必ず揃えてください。** **詰まったら:** 赤に戻らない場合は `gcloud run services update-traffic handson-app --region ${REGION} --to-latest` をもう一度実行してください(何度実行しても同じ結果になる冪等なコマンドです)。それでも青いままなら、v2 のリビジョンが作られていない可能性があるため `gcloud run revisions list --service handson-app --region ${REGION}` で2つあるかを確認し、1つしかなければ「2. ビルドして push して deploy」からやり直します。

## まとめ

- デプロイのたびに不変のリビジョンが積み重なる

- ロールバック = 過去リビジョンへのトラフィック切り替え。**再デプロイ不要、数秒で完了**
- 「イメージの不変性」がプラットフォーム機能として活きている

次章では、このトラフィック制御をもっと攻めた使い方——カナリアリリースに使います。

## 6. カナリアリリースとタグ付きURL

前章のトラフィック制御を一步進めて、**新バージョンを10%のユーザーにだけ出すカナリアリリース**と、**トラフィックを流さずに本番環境で動作確認できるタグ付きURL**を体験します。

**AWSとの比較:** これを ECS でやるには CodeDeploy のブルー/グリーン+ALB の加重ターゲットグループの設定が必要でした(検証用リスナーは任意ですが、リリース前検証をしたいなら実質必要になります)。Cloud Run では**サービスに元から組み込まれた機能**です。

### 1. v3 を作る

`src/index.ts` を再度書き換えます。

```
const MESSAGE = "Hello, Cloud Run v3!";  
const BG_COLOR = "#34A853"; // 緑
```

ビルドと push まで行います(まだ deploy はしません)。

```
cd ~/cloudrun-handson/app  
docker build -t ${IMAGE}:v3 .  
docker push ${IMAGE}:v3
```

### 2. トラフィックを流さずにデプロイする

`--no-traffic` を付けてデプロイすると、リビジョンは作られますが**ユーザーへのトラフィックは1%も流れません**。

さらに `--tag` を付けると、そのリビジョン専用のURLが発行されます。

```
gcloud run deploy handson-app \  
  --image ${IMAGE}:v3 \  
  --region ${REGION} \  
  --no-traffic \  
  --tag staging
```

出力の最後に、このリビジョン専用のタグ付きURLが表示されます(`--no-traffic` のときは `Service URL:` の行は出ません)。

本番URLは4章で取得したものと同じです。

- 本番URL: `https://handson-app-<プロジェクト番号>.asia-northeast1.run.app` → **まだ赤(v2)のまま**
- タグ付きURL: `https://staging---handson-app-xxxxx-an.a.run.app` → **緑(v3)**

両方をブラウザで開いて確認してください。

**本番と同じ環境・同じ設定で、リリース前のバージョンだけを検証できるURL**が手に入りました。

ステージング環境を別に組む代わりに、本番サービスの中に検証チャンネルを持てるということです。

**成功していれば:** 出力に `serving 0 percent of traffic` と `The revision can be reached directly at https://staging--...` の2点が出ます。タグ付きURLは緑(v3)、本番URLは赤(v2)のままです。URLを見失ったら `gcloud run services describe handson-app --region ${REGION}` の出力で本番URLとタグ付きURLの両方を確認できます。なお **リビジョン名の番号は 00003 にならないことがあります**。番号の採番はデプロイ回数と一致せず、`handson-app-00005-xxx` のように飛ぶことがあります(リビジョンを見分けるのは末尾のランダム文字列です)。番号が飛んでいても失敗ではありません。 **詰まったら:** 本番URLまで緑になってしまった場合は `--no-traffic` が効いていません(タイプミスや行末の `\` の抜けが原因です)。`gcloud run revisions list --service handson-app --region ${REGION}` で v2 のリビジョン名を確認し、5章の手順で `--to-revisions <v2のリビジョン名>=100` を実行して赤に戻してから、`--no-traffic --tag staging` を付けてデプロイし直してください。タグ付きURLが 404 を返す場合は、`gcloud run services describe` に出ている URL をそのままコピーし直します(`staging---` の3連ハイフンが崩れやすい箇所です)。`docker push` からのやり直しが必要な場合は `cd ~/cloudrun-handson/app` と4章の「0. 環境変数の準備」を先に確認してください。

#### [要作図] 図5: デプロイとリリースの分離

- **目的:** 「1つのサービスの中に本番チャンネルと検証チャンネルが同居する」構造を見せる。ステージング環境を別に建てる発想との違いが要点
- **描き方:** 1つの「Cloud Run サービス」の箱の中にリビジョン3つ(v1 / v2 / v3)を並べ、箱の外から2種類のURLが別々の矢印で入ってくる形にする
  - 本番URL( `handson-app-...run.app` ) → v2 へ 100%
  - タグ付きURL( `staging---handson-app-...run.app` ) → v3 へ(トラフィック割当は 0%)
- **要点:** v3 は「デプロイ済みだがリリースされていない」状態にあること。**デプロイ(コードを載せる)とリリース(ユーザーに出す)が別の操作**であることを図で言い切る
- **続きのコマ(任意):** カナリア時に本番URLからの矢印が 90% / 10% に分かれる図を並べると、次の節にそのままつながる
- **完成後の扱い:** `06_traffic/imgs/deploy-release-separation.png` として保存し、**見出しの直下に** `![デプロイとリリースの分離](imgs/deploy-release-separation.png)` として差し込む(見出し → 画像 → 本文の順。キャプション文は付けない)

## 3. 10%だけ流す(カナリアリリース)

v3 の動作確認が取れた想定で、まず10%のユーザーにだけ出します。

```
gcloud run services update-traffic handson-app \  
  --region ${REGION} \  
  --to-tags staging=10
```

確認してみましょう。

`/api` エンドポイントを20回叩いて、どのリビジョンが応答したかを集計します。



```
URL=$(gcloud run services describe handson-app --region ${REGION} --format 'value(status.url)')
```

```
for i in $(seq 1 20); do curl -s ${URL}/api | jq -r .revision; done | sort | uniq -c
```

リビジョン名が2種類表示され、`18 handson-app-00002-vjk` のように v2 のリビジョンが18回・v3 のリビジョンが2回、という比率になるはずです。

ブラウザを何度もリロードして「たまに緑が出る」のを見るのも楽しいです。

実務ではこの状態でエラーレートやレイテンシのメトリクス(8章)を監視し、問題なければ段階的に割合を増やしていきます。

**成功していれば:** `gcloud run services describe handson-app --region ${REGION}` の Traffic 欄が `90% handson-app-00002-xxx` と `10% handson-app-000xx-xxx` (その下に `staging: https://staging---...` が付きます)に分かれ、20回の集計でも v3 のリビジョン名が数回混ざります。10%の乱数なので v3 のリビジョン名が0回や4回になることもあり、比率が多少ずれても失敗ではありません。**詰まったら:** 切り替え直後は反映に数秒かかるため、集計が v2 のリビジョン名だけだった場合はもう一度 for ループを実行してください。`jq: command not found` の場合は `for i in $(seq 1 20); do curl -s ${URL}/api; echo; done` で生の JSON を見れば十分です。`URL` が空(`curl` が使い方を表示する)場合は `echo ${URL}` を確認し、`describe` のコマンドを再実行して代入し直します。`Tag 'staging' not found` と出た場合は「2. トラフィックを流さずにデプロイする」のタグ付きデプロイが成功していないので、そちらをやり直してください。

## 4. 100%に昇格する

```
gcloud run services update-traffic handson-app \  
  --region ${REGION} \  
  --to-latest
```

`--to-latest` は「いま動いているリビジョンに固定する」という意味ではなく、**LATEST (=最新リビジョン)に100%割り当て**という設定です。そのため、この状態で次のデプロイを行うと、新しく作られたリビジョンがそのまま **LATEST** になってトラフィックを受け取ります(4~5章で体験した普通のデプロイ挙動に戻る、ということです)。

ブラウザで全リロードが緑(v3)になれば完了です。

もし v3 に問題が見つかったら?——前章でやった通り、v2 に一瞬で戻せます。

**成功していれば:** Traffic 欄に `100% LATEST (currently handson-app-000xx-xxx)` が現れ、上の for ループを再実行すると20回すべて v3 のリビジョン名になります。`staging` タグ自体は残るので、Traffic 欄には `0% (currently -) handson-app-000xx-xxx` と `staging (Adding): / staging (Deleting): https://staging---...` という行も並びます。**これは表示上の見え方で、トラフィックは 100% 最新リビジョンに向いています**(for ループの結果が20回すべて同じ v3 のリビジョン名ならそれが答えです)。**詰まったら:** まだ赤が混ざる場合は10~20秒待って再度集計してください(切り替えは瞬時ではありません)。それでも混ざるなら `gcloud run services update-traffic`

`handson-app --region ${REGION} --to-latest` を再実行します。何度実行しても結果は同じです。最新リビジョンが v3 でない場合は `gcloud run revisions list --service handson-app --region ${REGION}` で3つ並んでいるかを確認し、足りなければ「2. トラフィックを流さずにデプロイする」からやり直してください。

## まとめ

- `--no-traffic` + `--tag` で「デプロイ」と「リリース」を分離できる
- タグ付きURLで、本番環境そのものを使ったリリース前検証ができる
- カナリア → 段階的昇格 → 即ロールバック、が追加インフラなしで完結する

デプロイのたびに緊張するチームほど、この機能の価値は大きいはずです。

## 7. オートスケールを観察する

Cloud Run の非機能まわりの主役、オートスケールを実際に負荷をかけて観察します。  
あわせてコールドスタートとその対策も体験します。

オートスケールや非機能要件の背景を体系的に知りたい人は [クラウドを今から学ぶには](#) も参照してください。

### Cloud Run のスケールの仕組み

Cloud Run は同時に処理しているリクエスト数(concurrency)とCPU使用率を基準にインスタンス数を自動調整します。

必要インスタンス数  $\approx$  同時リクエスト数  $\div$  concurrency(1台が同時に受ける数)

- この式は**キャパシティの直感をつかむための概算**です。実際のオートスケーラーは同時リクエスト数とCPU使用率の平均を見て、**どちらも既定で目標値60%以下に収まるように台数を決めるため**、計算どおりの整数台にはなりません(たいてい式より多めの台数になります)
- concurrency は1 vCPU構成なら既定80(gcloud / Terraform で新規作成した場合は「vCPU数 × 80」)。1 インスタンスあたり最大1000まで上げられます。**標準のLambda(1リクエスト=1環境)と違い、1台で複数リクエストを捌く**
- トラフィックが来なくなると0台までスケールインする(スケールtoゼロ)。ただし縮小は即座ではなく、**次のスパイクに備えて最大15分ほどインスタンスがアイドルのまま残ります**
- ECS のように Application Auto Scaling でスケーリングポリシーを登録する必要はなく、**設定不要で最初から動いている**(ECS もターゲット追跡ポリシーを使えば CloudWatch アラーム自体は AWS 側が自動生成してくれますが、ポリシーを登録する作業そのものは必要です)

#### [要作図] 図6: concurrency とインスタンス数の関係

- 目的:** 「1インスタンスが複数リクエストを同時に受ける」という Lambda との最大の違いを絵で理解させる
- 描き方:** 同じ50本の同時リクエストを、2つの設定で受けた場合を左右に並べる
  - 左: concurrency 80 — インスタンス1台に50本が束になって入る
  - 右: concurrency 10 — 1台が受けるのは10本まで。結果として複数台に分かれる
- 要点:** 右の台数を「5台」と描き切らないこと。オートスケーラーは目標60%以下に保とうとするため実際は**5台より多くなる**。「式では5台、実測は上限の10台まで増えた」と図中に注記を入れて、**台数は当てるものではなく観察するもの**という本文の姿勢と揃える
- 注意:** 「実測は上限の10台」は負荷対象リビジョンの台数(active 9 + idle 1)の1回の実測値。当日の値は変わるので、図7 と同様に図中に「実測例」と明記する
- 比較(任意):** 同じ50本を標準の Lambda で受けた場合(1リクエスト=1環境で50環境)を薄く添えると、コンテナ側の効率が際立つ

- 完成後の扱い: 07\_scaling/imgs/concurrency-and-instances.png として保存し、見出しの直下に !  
[concurrency とインスタンス数の関係](imgs/concurrency-and-instances.png) として差し込む(見出し → 画像 → 本文の順。キャプション文は付けない)

## 1. 観察しやすいように設定を変える

デフォルトの concurrency 80 だとなかなかスケールしないので、実験用に1台あたり10接続に絞り、上限を10台にします。

```
gcloud run services update handson-app \  
  --region ${REGION} \  
  --concurrency 10 \  
  --max-instances 10
```

この操作でも新しいリビジョンが作られます。リビジョン=イメージ+設定のスナップショットだからです。

## 2. 負荷をかける

負荷試験スクリプトを作ります。

Node.js の標準APIだけで動く31行のスクリプトで、外部ツールのダウンロードは不要です(Cloud Shell には Node.js が入っています)。

```
cat > ~/load.mjs <<'EOF'  
  
// 簡易負荷試験スクリプト。Node.js 標準APIのみで動く(外部バイナリのダウンロード不要)。  
  
//  node load.mjs <URL> [同時接続数=50] [継続秒数=30]  
  
const [url, concurrency = "50", duration = "30"] = process.argv.slice(2);  
  
if (!url) {  
  console.error("usage: node load.mjs <URL> [concurrency] [durationSec]");  
  process.exit(1);  
}  
  
const until = Date.now() + Number(duration) * 1000;  
  
let ok = 0;  
let ng = 0;  
  
const worker = async () => {  
  while (Date.now() < until) {  
    try {  
      // タイムアウトを入れないと、サーバー無応答時にワーカーが張り付いて  
      // 指定した継続秒数を過ぎても終わらなくなる  
      const res = await fetch(url, { signal: AbortSignal.timeout(10000) });  
      ok++;  
    } catch {  
      ng++;  
    }  
  }  
}
```

```

    await res.arrayBuffer(); // レスポンスを読み切って接続を再利用する
    if (res.ok) ok++;
    else ng++;
  } catch {
    ng++;
  }
}
};

console.log(`load: ${url} concurrency=${concurrency} duration=${duration}s`);
await Promise.all(Array.from({ length: Number(concurrency) }, worker));
console.log(`done: success=${ok} failure=${ng}`);

EOF

```

アプリの `/heavy` は1秒かかる擬似的に重いエンドポイントです。  
 同時50接続で30秒間叩きます。

**実行する前に、何台までスケールアウトするか予想してみてください。**

concurrency を10に絞ったので、1台で受けられる同時リクエストは10。  
 50接続なら式のうえでは5台です。

ただしオートスケーラーは同時リクエスト数を目標値(既定60%)以下に保とうとするため、実際には5台より多く、8台前後や上限の10台まで立ち上がることもあります。

**台数は当てるものではなく観察するものです。**

予想と違ったら「なぜ?」を考えるのがこの実験の面白いところです。

```

URL=$(gcloud run services describe handson-app --region ${REGION} --format 'value(status.url)')

node ~/load.mjs ${URL}/heavy 50 30

```

### 3. 観察する

負荷をかけている間(および直後)に、2つの方法で観察します。

**コンソールで:** [Cloud Run](#) → `handson-app` → 「指標」タブ。

「コンテナ インスタンスの数」がゼロから跳ね上がり、負荷を止めたあと最大15分ほどかけてまたゼロに戻っていく様子が見えます。

リクエスト数・レイテンシ(p50/p95/p99)・CPU使用率も何も設定していないのに最初から揃っています。

**手元で:** `/api` はインスタンスごとに違う `instance` ID を返します。

何台に分散しているか数えてみましょう。

```

for i in $(seq 1 30); do curl -s ${URL}/api | jq -r .instance; done | sort | uniq -c

```

複数の instance ID が出来れば、リクエストが複数台に分散している証拠です。  
負荷を止めてから数分〜15分ほど待って同じコマンドを打つと、1台(やがて0台)に戻ります。

**成功していれば:** `node ~/load.mjs` の最後に `done: success=<数百~数千> failure=0` (起動中のリクエストが少数失敗することはあります)が表示され、`sort | uniq -c` の出力に **2つ以上の instance ID** が並びます。コンソールの「コンテナ インスタンスの数」もゼロ(または1台)から複数台へ跳ね上がっています。台数は実行ごとに変わるので、5台でなくても失敗ではありません。 **詰まったら:** `Cannot find module '/home/xxx/load.mjs'` と出る場合は `~/load.mjs` が作られていません。「2. 負荷をかける」の `cat > ~/load.mjs <<'EOF'` から `EOF` までをもう一度そのまま貼り付けて作り直してください(上書きされるので何度実行しても大丈夫です)。`Invalid URL` と出る、または `${URL}` が空の場合は Cloud Shell の再接続で環境変数が消えているので、  
[4章の「0. 環境変数の準備」](#)を再実行したうえで `URL=$(gcloud run services describe handson-app --region ${REGION} --format 'value(status.url)')` を実行し直し、`echo ${URL}` で URL が表示されることを確認します。instance ID が1種類しか出ない場合は concurrency の変更が効いていない可能性があるため、`gcloud run services describe handson-app --region ${REGION} --format 'value(spec.template.spec.containerConcurrency)'` が `10` を返すか確認し、違っていれば「1. 観察しやすいように設定を変える」を再実行してから負荷をかけ直してください。

## 4. コールドスタートと min-instances

スケールtoゼロの代償がコールドスタートです。  
0台の状態への最初のリクエストは、コンテナ起動を待つ分だけ遅くなります。

### [要作図] 図7: 負荷をかけてから0台に戻るまでのタイムライン

- **目的:** 「スケールインは即座ではない」という、当日いちばん誤解される挙動を時間軸で見せる。この図があると「10分待っても0台にならない」という詰まりを予防できる
- **描き方:** 横軸=時間、縦軸=インスタンス数の折れ線グラフ。実測値をそのまま使う
  - 負荷中のピークは合計11台(負荷対象リビジョンが上限の10台 + 旧リビジョンのアイドル1台)。  
上限10台の水平線を引き、旧リビジョンの1台は色を分けて積み上げると、上限を超えたわけではないことが伝わります
  - 負荷停止から約5分後に7台
  - その後2台まで落ち、最後のリクエストから13分後もまだ1台残っている
  - 16分後に0台。ここで初めて次のリクエストがコールドスタート(実測1.45秒)になる
- **要点:** 「最大15分アイドル保持」の帯を横向きに塗って、その間は0台にならないことを視覚的に示す
- **注意:** これは1回の実測値。当日の値は変わるので、図中に「実測例」と明記する
- **完成後の扱い:** `07_scaling/imgs/scale-in-timeline.png` として保存し、見出しの直下に `![負荷をかけてから0台に戻るまでのタイムライン](imgs/scale-in-timeline.png)` として差し込む(見出し → 画像 → 本文の順。キャプション文は付けない)

Cloud Run は最大15分ほどインスタンスをアイドルのまま残すので、0台に戻るのを待つには**15分以上**放置する必要があります。

講師の説明を聞いたあとなど、しばらく間を置いてから1発目のレスポンスタイムを計ってみてください。

```
curl -s -o /dev/null -w "time_total: %{time_total}s\n" ${URL}/
curl -s -o /dev/null -w "time_total: %{time_total}s\n" ${URL}/
```

1回目だけ遅い(このアプリは軽いですが、0台の状態からだとも1秒〜1.5秒ほどかかります。重いアプリではさらに長くなります)のがわかります。

対策は常時1台温めておくことです。

```
gcloud run services update handson-app \
  --region ${REGION} \
  --min-instances 1
```

**トレードオフ:** min-instances を設定した分はアイドル時も課金されます(リクエスト課金の場合、アイドル中は低い単価が適用されます)。「完全従量制(コールドスタートあり)」と「最低台数の固定費(コールドスタートを起きにくくする)」を、**サービスごとにダイヤルで選べる**のが Cloud Run の良いところです。Lambda の Provisioned Concurrency と ECS の常駐、両方の選択肢が1つのサービスに入っていると考えてください。なお min-instances は「温かいインスタンスを保つベストエフォート」であり、コールドスタートがゼロになる保証ではありません。

確認できたら、課金を避けるため戻しておきます。

```
gcloud run services update handson-app \
  --region ${REGION} \
  --min-instances 0
```

**成功していれば:** 1回目の `curl` の `time_total` が2回目より明確に大きくなります(このアプリなら1回目1秒〜1.5秒、2回目は数十ms程度)。 `--min-instances` の更新はどちらも新しいリビジョン名を出力して完了し、`gcloud run revisions list --service handson-app --region ${REGION}` の行が増えます。 **詰まったら:** 1回目と2回目で差が出ない場合は、まだインスタンスがアイドルのまま残っています(Cloud Run は最大15分保持します)。時間を置いて試すか、差が出なくても「温まっていた」ということなので先へ進んでください。リージョンの入力を求められたり `--region` が空だと言われる場合は Cloud Shell の再接続で環境変数が消えているので、[4章の「0. 環境変数の準備」](#)を再実行します。更新が途中で失敗した場合は、同じコマンドをそのまま再実行すれば復旧します。 **最後の `--min-instances 0` を実行し忘れるとアイドル時も課金が続きます。** 不安なら上のコマンドをもう一度実行して構いません(同じ設定への更新は何度でも安全です)。

## まとめ

- スケールの基準は同時リクエスト数とCPU使用率。台数は「同時リクエスト数 ÷ concurrency」で概算でき、設定ゼロで動く
- スケールtoゼロ ⇔ コールドスタートはトレードオフ。 `min-instances` で調整(縮小には最大15分のアイドル時間がある)
- `max-instances` は暴走課金・下流(DB)保護の安全弁としても重要



## 8. ログとメトリクスをのぞく

短い章です。

ここまでのハンズオンで一度も「ログの設定」をしていないのに、実はすべて記録されています。

それを見に行きます。

### [要作図] 図8: ログとメトリクスが勝手に集まる経路

- **目的:** 「設定していないのに記録されている」理由を、経路として示す。1章の主題(消える意思決定)がログの領域でも成り立つことを見せる
- **左(AWS/ECS):** 同じことをするのに**自分で用意する必要があったもの**——awslogs ログドライバの設定、ロググループの作成、タスク実行ロールへの `logs:CreateLogStream` / `logs:PutLogEvents` 権限——を箱で並べる
- **右(Cloud Run):** アプリの stdout / stderr → Cloud Logging → Logs Explorer。並行して Cloud Run 自身 → Cloud Monitoring → 指標タブ。右の箱はすべて「プラットフォームが用意済み」の色で塗り、参加者が用意した箱は0個であることを凡例で示す
- **要点:** 比べるのは箱の総数ではなく「**自分で用意した箱の数**」(左は3個、右は0個)。図1と同じ左右配置(左=AWS、右=Cloud Run)を使うと、教材を通した一貫したメッセージになる
- **完成後の扱い:** `08_observability/imgs/logs-and-metrics-flow.png` として保存し、**見出しの直下に** `![ログとメトリクスが勝手に集まる経路](imgs/logs-and-metrics-flow.png)` として差し込む(見出し → 画像 → 本文の順。キャプション文は付けない)

## 1. ログを見る

[Cloud Run のコンソール](#) → `handson-app` → 「ログ」タブを開いてください。

- コンテナが stdout/stderr に出しただけのログが、すべて収集されている
- アプリが出していた `{"severity": "INFO", "message": "index accessed", ...}` という1行JSONが**構造化ログとして解釈され**、severity で色分けされている

CLI からも見られます:

```
gcloud run services logs read handson-app --region ${REGION} --limit 20
```

**成功していれば:** `2026-01-01 12:34:56 GET 200 https://handson-app-.../` のようなリクエストログと、`listening on port 8080` のようなアプリの出力が時刻順に並びます。

ただし `gcloud run services logs read` はログ本文を**プレーンテキストとしてしか表示しない**ため、アプリが出した1行JSON(`index accessed`)は**時刻だけの空行**に見えます。JSON の中身まで CLI で見たいときはこちらを使ってください。

```
gcloud logging read 'resource.type="cloud_run_revision" AND resource.labels.service_name="handson-app" AND
```



```
jsonPayload.message="index accessed" --limit 5 --format 'yaml(timestamp,severity,jsonPayload)'
```

**詰まったら:** 何も表示されない場合、まだリクエストが発生していないことがほとんどです。次を実行してアクセスを作ってから、もう一度ログを読み直してください。

```
URL=$(gcloud run services describe handson-app --region ${REGION} --format 'value(status.url)')
curl -s -o /dev/null ${URL}/
```

`${REGION}` が空のまま実行するとエラーになります。Cloud Shell を開き直した場合は、[4章の「0. 環境変数の準備」](#)をもう一度実行してください。サービスそのものが見つからないときは `gcloud run services list --region ${REGION}` で名前を確認してください。

**AWSとの比較:** CloudWatch Logs へ送るには awslogs ログドライバやロググループの設定、IAM 権限が必要でした。Cloud Run では**コンテナが stdout に書く、以上**です。構造化ログにしたければ1行JSONにするだけで、フィールド検索・severityフィルタが効くようになります。

## 2. Logs Explorer で検索する

「ログ」タブの上部から「ログ エクスプローラで表示」を開くと、プロジェクト全体のログを横断検索できます。クエリ欄に以下を入れてみてください:

```
resource.type="cloud_run_revision"
resource.labels.service_name="handson-app"
jsonPayload.message="index accessed"
```

アプリが出した構造化ログだけに絞り込めます。

`jsonPayload.instance` など、`log()` 関数で自分が入れたフィールドもそのまま検索条件に使えます。

**成功していれば:** `index accessed` の行だけが残ります。

**詰まったら:** 0件のときは、まず検索期間を「過去1時間」程度に広げてください。それでも0件なら

`jsonPayload.message="index accessed"` の行を消し、リソース指定の2行だけで結果が出るかを確認めます。このログはトップページ(/)へのアクセスでのみ出力されるので、`/api` だけを叩いていた場合は先に `/` を開いてください。

## 3. メトリクスを見る

「指標」タブ(7章でも見ました)には以下が最初から揃っています:

- リクエスト数 / レイテンシ(p50, p95, p99)
- コンテナインスタンス数 / 課金対象インスタンス時間
- CPU / メモリ使用率

実務では、6章のカナリアリリース中にこの画面を開き、「新リビジョンだけエラー率が上がっていないか」を見ながら昇格判断をします。

リビジョン別にメトリクスをフィルタできることも確認してみてください。

**成功していれば:** リクエスト数のグラフに、ここまでのアクセス分が現れます。

**詰まったら:** グラフが空に見えても壊れてはいません。メトリクスは集計されるまで数分かかることがあるので、表示期間を広げて少し待ってから再読み込みしてください。ここで足を止める必要はないので、先に進んで最後に見に戻るのでも構いません。

## まとめ

- ログもメトリクスも「設定する」のではなく「最初からある」
- アプリ側の作法は「stdout に(できれば1行JSONで)書く」だけ
- 1章で話した SaaS 的アプローチは、オブザーバビリティにも一貫している

## 9. 締め: Dockerfileすら書かないデプロイ

最後に、今日学んだ手順を巻き戻すような機能を紹介します。

ソースコードだけで Cloud Run にデプロイする方法です。

### ソースデプロイ

`--image` の代わりに `--source` を指定すると、Cloud Build がソースからイメージをビルドして GAR に push し、そのままデプロイまで行います。

```
cd ~/cloudrun-handson/app
gcloud run deploy handson-app-src \
  --source . \
  --region ${REGION} \
  --allow-unauthenticated
```

数分待つと、別サービス `handson-app-src` として同じアプリが公開されます。

**成功していれば:** ビルドとデプロイに数分かかったあと、`Service URL: https://handson-app-src-...` が表示されます。開くと4章と同じレイアウトの画面が出ますが、色とメッセージは緑の **v3** です(6章で `src/index.ts` を `v3` に書き換えたまま進めているので、ソースからビルドされるのは `v3` のコードです)。`Service` の欄が `handson-app-src` になっていることも確認してください。初回はビルド済みイメージの置き場として `cloud-run-source-deploy` という Artifact Registry リポジトリが自動で作られます(確認を求められたらそのまま進めてください)。途中で出力が止まって見えても、ビルド待ちなので待つで大丈夫です。

**詰まったら:** `${REGION}` が空だとエラーになります。Cloud Shell を開き直した場合は [4章の「0. 環境変数の準備」](#) を再実行してください。`cd ~/cloudrun-handson/app` の位置で実行しているか、`ls` に `package.json` があるかも確認してください。失敗したら**同じコマンドをもう一度実行して構いません**(何度実行しても新しいリビジョンが増えるだけです)。デプロイできたかどうかは `gcloud run services list --region ${REGION}` で確認できます。

#### [要作図] 図3b: 図3 との差分(ソースデプロイ)

- **目的:** 4章の図3 と同じ構図を使い、`docker build` と `docker push` の2ステップがプラットフォーム側へ移ったことを差分として見せる
- **描き方:** 図3 のレイアウトをそのまま流用し、`docker build` / `docker push` の2箱を破線で囲んで「Cloud Build が代行」とラベルを付ける。参加者が打つコマンドは `gcloud run deploy --source .` の1つだけになることを強調する
- **要点:** 図3(4章)と**同一のレイアウト・同一の箱の位置**にすること。並べて見せて差分が読めることが唯一の要件

- **完成後の扱い:** 09\_source\_deploy/imgs/source-deploy-diff.png として保存し、**見出しの直下に** `![ソースデプロイでプラットフォーム側へ移るステップ](imgs/source-deploy-diff.png)` として差し込む(見出し → 画像 → 本文の順。キャプション文は付けない)

このディレクトリには Dockerfile があるのでそれが使われますが、**Dockerfile を消しても動きます**。  
その場合は [Google Cloud の Buildpacks](#) が `package.json` を見て「Node.js アプリだな」と判断し、`scripts.start` (この教材では `node src/index.ts`) を起動コマンドにした良い感じのイメージを自動生成します。

**成功していれば:** Dockerfile を消して同じ `gcloud run deploy handson-app-src --source . --region ${REGION} --allow-unauthenticated` を実行しても、やはり数分後に同じ画面が返ってきます。切り替わったかどうかは出力の1行目で分かります。Dockerfile があるときは `Building using Dockerfile and deploying container to Cloud Run service [handson-app-src]`、消したあとは `Building using Buildpacks and deploying container to Cloud Run service [handson-app-src]` になります。

**詰まったら:** Buildpacks は `package.json` の `scripts.start` をそのまま起動コマンドに使います。ビルドは通ったのに URL を開くとエラーになる場合は、`scripts.start` が `node src/index.ts` になっているかを確認してください。原因は次で確かめられます。

```
gcloud run services logs read handson-app-src --region ${REGION} --limit 20
```

Dockerfile を消したくない場合は、この節は読むだけで先に進んでも構いません。

**AWSとの比較:** App Runner のソースデプロイに相当しますが、できあがるものは今日ずっと触ってきた「普通の Cloud Run サービス」です。カナリアも、タグ付きURLも、スケール設定も全部同じように使えます。

## では、なぜ今日 Dockerfile から始めたのか

「最初からこれを教えてくれれば良かったのに」と思うかもしれません。  
でも順番には意図があります。

- ソースデプロイは**中でやっていることが今日の手順そのもの**です(build → push → deploy)。仕組みを知った上で使う自動化と、知らずに使う魔法は違います
- 実務では Dockerfile を書く場面が必ず来ます(依存OSパッケージ、マルチステージビルド、社内ベースイメージ…)
- 逆に、プロトタイプや社内ツールなら「Dockerfile なしでとりあえず公開」で十分なことも多い

手軽さの階段を自分で選べるのが Cloud Run です:

```
gcloud run deploy --source .           # ソースだけ(Buildpacksにおまかせ)
gcloud run deploy --source .           # ソース+ Dockerfile(ビルドはおまかせ)
docker build && push && deploy          # 全部自分で制御(今日やったこと)
+ Cloud Build トリガー                 # git push で自動デプロイ(CI/CD)
```

## 今日のまとめ

1. **AWSはビルディングブロック、Google CloudはSaaS的アプローチ** — deploy 1 コマンドの裏で、LB・証明書・スケーリング・ログ収集を「しなかった」
2. **イメージの不変性がプラットフォームまで買われている** — リビジョン、ロールバック、カナリア、タグ付きURL
3. **従量課金と常駐のダイヤルを回せる** — スケールtoゼロ、concurrency、min/max-instances

AWS に帰っても、この目線は使えます。

「この構成、Cloud Run 的な発想ならどう簡単にできるか?」「App Runner や Lambda で十分では?」——別のクラウドを知ることは、いま使っているクラウドをより良く使うことにつながります。

時間に余裕があれば[発展編](#)へ。

終わったら必ず[後片付け](#)をしてください。

# 10. 発展編

3時間版で扱う(または2時間版では講師デモとして見せる)コンテンツです。  
Cloud Run 単体の体験から一歩進んで、他のサービスとの連携のしやすさと、「Webサーバー」以外のワークロードを体験します。

| 節                                    | 内容                   | 形式          | 所要時間 |
|--------------------------------------|----------------------|-------------|------|
| <a href="#">10-1. Pub/Subとつなぐ</a>    | イベント駆動アーキテクチャを3コマンドで | ハンズオン       | 20分  |
| <a href="#">10-2. WebSocketチャット</a>  | ALBなしでWebSocketが動く   | デモ(全員参加)    | 10分  |
| <a href="#">10-3. Cloud Run Jobs</a> | リクエスト駆動ではないバッチ処理     | デモ or ハンズオン | 10分  |

## ここで伝えたいこと

4〜9章で見てきた Cloud Run は「Webサービスの実行基盤」でした。  
発展編で見るのはその周辺です。

- **Pub/Sub 連携** — Lambda + SQS で組んでいたイベント駆動が、「普通のHTTPサーバーにPOSTが飛んでくる」だけの世界になる
- **WebSocket** — 「サーバーレスでは無理」と思われがちなワークロードが普通に動く
- **Jobs** — 同じイメージ・同じ開発体験のまま、バッチにも使える

いずれも「Cloud Run が特別多機能」というより、「ただのコンテナ・ただのHTTP」という抽象を守っているから、何とでもつながるという話です。

## さらにその先(講師からの紹介のみ)

手を動かすには2〜3時間の枠に収まりませんが、2025〜2026年の Cloud Run はさらに広がっています。  
興味があれば持ち帰って調べてみてください。

- **Worker pools**(2026年4月GA) — 3章で触れた第3の実行モデル。Pub/Sub pull や Kafka コンシューマのような常駐ワーカーを Cloud Run で動かせる
- **GPU対応**(NVIDIA L4等) — GPUワークロードでも **スケールtoゼロ**が効く。LLM推論を「使うときだけ起動」で運用できる
- **Docker Compose デプロイ**(2026年3月GA) — `compose.yaml` をそのまま Cloud Run へ。サイドカー構成も持ち込める
- **IAP 直接統合**(2026年3月GA) — ロードバランサーを組まずに、社内向けアプリに Google アカウント認証を付けられる

## 10-1. Pub/Subとつなぐ

Cloud Run を Pub/Sub のサブスクライバーにして、イベント駆動アーキテクチャを体験します。

### AWSでの構成と比べる

「S3にファイルが置かれたら処理する」「注文イベントを非同期で処理する」——AWS なら SNS + SQS + Lambda(またはSQSポーリングのECS)で組む定番パターンです。

Lambda には専用のハンドリングネチャがあり、SQS はポーリング設定やバッチサイズの調整が必要でした。

Google Cloud では **Pub/Sub がサブスクライバーのHTTPエンドポイントに直接 POST してくれます**(push 型)。

受け側は「POSTを受けるだけの普通のWebサーバー」でよく、つまり今日デプロイしたアプリがそのまま使えます。

#### [要作図] 図9: pull型とpush型の違い

- **目的:** 「受け側が普通のWebサーバーでよい」理由を、矢印の向きの違いとして見せる
- **上(AWS):** SNS → SQS → Lambda。矢印は **Lambda 側から SQS へ向かう**(ポーリングして取りに行く)。Lambda の箱には「専用のハンドリングネチャ」と注記
- **下(Cloud Run):** Pub/Sub トピック → サブスクリプション → 矢印は **Pub/Sub 側から Cloud Run へ向かう**(POSTしてくる)。Cloud Run の箱には「`POST /pubsub` を受けるだけの普通のWebサーバー」と注記
- **要点:** 矢印の向きが逆であること。取りに行く側と、届けられる側の違いがこの節の本質
- **認証付きの場合(任意):** 本番構成では Pub/Sub のサービスエージェントが OIDC トークンを取得して付与する流れが入る。別コマとして描くなら、「サービスアカウント」  
「`roles/iam.serviceAccountTokenCreator`」「`roles/run.invoker`」の3つがどこに効くかを示すと、章末の補足が理解しやすくなる
- **完成後の扱い:** `10_advanced/imgs/pull-vs-push-delivery.png` として保存し、**見出しの直下に** `![pull型とpush型の配送の違い](imgs/pull-vs-push-delivery.png)` として差し込む(見出し → 画像 → 本文の順。キャプション文は付けない)

実は2章で作った `src/index.ts` には、こっそり受け口を仕込んであります:

```
// Pub/Sub push サブスクリプションの受け口(発展編で使用)
app.post("/pubsub", async (c) => {
  const envelope = await c.req.json().catch(() => ({}));
  const data: string = envelope?.message?.data ?? "";
  const text = data ? Buffer.from(data, "base64").toString("utf-8") : "(empty)";
  log("INFO", `Pub/Sub message received: ${text}`);
  return c.body(null, 204);
});
```

この章の構成は「配送の仕組みを短時間で観察する」ためのハンズオン用ショートカットです。認証なしの公開エンドポイントに push する構成を本番で使ってはいけません。実務では本章末尾の「本番に向けた補足」にある、サービスアカウント+OIDC トークンによる認証付き push を使います。先に認証を外しているのは、Pub/Sub の配送と IAM を一度にデバッグしなくて済むようにするためです。

## 1. トピックとpushサブスクリプションを作る

```
gcloud pubsub topics create handson-topic

URL=$(gcloud run services describe handson-app --region ${REGION} --format 'value(status.url)')

gcloud pubsub subscriptions create handson-sub \
  --topic handson-topic \
  --push-endpoint ${URL}/pubsub
```

これで配線は完了です。

SQSキューの作成、イベントソースマッピング、IAMロール、バッチ設定……に相当する作業はありません。

**成功していれば:** Created topic [projects/.../topics/handson-topic]. と Created subscription [projects/.../subscriptions/handson-sub]. が表示されます。gcloud pubsub topics list に handson-topic、gcloud pubsub subscriptions list に handson-sub が1行ずつ出れば配線できています。**詰まったら:** ALREADY\_EXISTS は作成済みという意味なので、そのまま次へ進んで構いません。--push-endpoint /pubsub のように URL が空で渡っている場合は URL の取得に失敗しています。まず echo \${REGION} が空でないか確認し、空なら 4章の「0. 環境変数の準備」を再実行してから URL=\$(gcloud run services describe handson-app --region \${REGION} --format 'value(status.url)') をやり直してください。handson-app が見つからないと言われる場合は gcloud run services list --region \${REGION} でサービス名を確認します。作り直したいときは gcloud pubsub subscriptions delete handson-sub で消してから、この節のコマンドをもう一度実行すれば同じ状態に戻せます。

## 2. メッセージを発行してみる

```
gcloud pubsub topics publish handson-topic --message "Hello from Pub/Sub"
```

数秒待ってからログを確認します:

```
gcloud run services logs read handson-app --region ${REGION} --limit 10
```

Pub/Sub message received: Hello from Pub/Sub が出ていれば成功です。

8章の Logs Explorer で見ると、severity INFO のログとして届いているのも確認できます(実測では、このログは jsonPayload ではなく本文だけのログとして記録されました)。



**成功していれば:** publish が `messageIds:` を返し、数秒後のログに `Pub/Sub message received: Hello from Pub/Sub` の1行が出ます。 **詰まったら:** 配送とログの反映には少し時間がかかります。まず10~20秒ほど待って `gcloud run services logs read handson-app --region ${REGION} --limit 10` をもう一度実行してください。それでも出ない場合は push 先が正しいかを確認します。 `gcloud pubsub subscriptions describe handson-sub --format 'value(pushConfig.pushEndpoint)'` の出力が、 `gcloud run services describe handson-app --region ${REGION} --format 'value(status.url)'` の URL + `/pubsub` になっているかを見比べてください。ずれていたら `gcloud pubsub subscriptions delete handson-sub` してから「1. トピックとpushサブスクリプションを作る」をやり直します。なお、この節の後にある「本番に向けた補足」の認証付き push を試している場合は、IAM の反映に数分かかるため一時的に 403 が返ります。数分待ってから publish を再実行してください。

### 3. ここで想像してほしいこと

- このエンドポイントが重い処理(画像変換、集計、通知送信)だったら? → **Pub/Sub が流量を受け止め、Cloud Run が処理量に応じてスケールアウトする**。バックプレッシャー付きの非同期処理基盤が、この3コマンドでできています
- 処理が失敗したら(2xx以外を返したら)? → Pub/Sub が自動でリトライします。デッドレタートピックも設定できます
- スケールtoゼロと組み合わせると? → イベントが来たときだけ起動して課金される、Lambda 的な使い方が「普通のWebサーバー」のままできます

### 本番に向けた補足

ハンズオンでは簡単のため認証なし( `--allow-unauthenticated` なサービス)に push しましたが、本番では以下のようになります:

- サービスを `--no-allow-unauthenticated` にして、Pub/Sub 用のサービスアカウントに `roles/run.invoker` を付与
- サブスクリプションに `--push-auth-service-account` を指定すると、Pub/Sub が OIDC トークン付きで POST してくれる
- あわせて Pub/Sub のサービスエージェント( `service-<プロジェクト番号>@gcp-sa-pubsub.iam.gserviceaccount.com` )に `roles/iam.serviceAccountTokenCreator` を付与します。これがないと Pub/Sub が OIDC トークンを生成できません
- IAM 付与の直後は反映まで数分かかり、その間 403 が返ることがあります(数分待ってリトライ)

「サービス間の認証を IAM とIDトークンでやる」のは Cloud Run 全般のパターンで、内部マイクロサービス間の呼び出しも同じ仕組みで守れます(ALB の内部リスナーやセキュリティグループの代わりに、IAM で「誰が呼べるか」を制御するイメージです)。

さらに Pub/Sub 以外にも、**Eventarc** を使うと Cloud Storage のファイル作成や監査ログなど60以上のイベントソースから Cloud Run を起動できます(EventBridge 相当)。

**Cloud Scheduler**(cron)や **Cloud Tasks**(遅延・レート制御付きキュー)も、同じく「HTTPエンドポイントを叩く」という形で Cloud Run と連携します。

## 後片付け(この節の分)

```
gcloud pubsub subscriptions delete handson-sub
```

```
gcloud pubsub topics delete handson-topic
```

## 10-2. WebSocketチャット

「サーバーレスでWebSocketは無理」という常識(Lambda 単体では扱えず、API Gateway の WebSocket API + DynamoDB で接続管理…)を、Cloud Run があっさり覆すのを見ます。

**進め方:** イベントでは講師がデプロイ済みのURLを画面に映し、**参加者全員がスマホやPCから同じチャットに参加**します。自分でもデプロイしたい人向けの手順も載せています(2章のスキルで全部できます)。

### なぜ Cloud Run で WebSocket が動くのか

Cloud Run のインスタンスは「普通のHTTPサーバーのプロセス」なので、コネクションを張りっぱなしにできます。

特別な設定はほぼ不要で、注意点は3つだけです:

- リクエストタイムアウト(デフォルト5分、最大60分)がコネクションにも適用される → `--timeout` を伸ばす。切断時はクライアントが再接続する設計にする
- 接続はインスタンスのメモリに紐づく → 複数インスタンス間で状態を共有するには Memorystore (Redis) 等が必要
- 再接続時に同じインスタンスへ戻したい → `--session-affinity` を付ける。ただし公式にはベストエフォートで、新しい WebSocket 接続が別のインスタンスにつながる可能性は残ります

### デプロイ手順(講師 or 自分でやりたい人向け)

コードはこのリポジトリの [code/websocket/](https://github.com/y-ohgi/handson-CloudRun/blob/main/code/websocket/) にあります。

本編と同じ TypeScript + Hono 製( `@hono/node-ws` を追加)の小さなチャットサーバーで、受け取ったメッセージを接続中の全クライアントにブロードキャストするだけのものです。

```
cd ~/cloudrun-handson
git clone https://github.com/y-ohgi/handson-CloudRun.git
cd handson-CloudRun/code/websocket

docker build -t ${REGION}-docker.pkg.dev/${PROJECT_ID}/${REPO}/chat:v1 .
docker push ${REGION}-docker.pkg.dev/${PROJECT_ID}/${REPO}/chat:v1

gcloud run deploy handson-chat \
  --image ${REGION}-docker.pkg.dev/${PROJECT_ID}/${REPO}/chat:v1 \
  --region ${REGION} \
  --allow-unauthenticated \
  --timeout 3600 \
  --session-affinity \
  --max-instances 1
```

`--max-instances 1` は、接続管理をインスタンスのメモリで済ませているこのデモアプリの都合です。1台に固定することで「全員が同じメモリ空間につながる」状態を作っています。

**成功していれば:** デプロイの最後に `Service URL: https://handson-chat-....run.app` が表示され、`gcloud run services list --region ${REGION}` に `handson-chat` が並びます。 **詰まったら:** イメージのパスが `-docker.pkg.dev//` のように途中が空になっている場合は、環境変数が消えています。4章の「0. 環境変数の準備」を再実行し、`cd ~/cloudrun-handson/handson-CloudRun/code/websocket` に移動してから `docker build` からやり直してください。`docker push` が `denied` や `unauthorized` で失敗する場合は `gcloud auth configure-docker ${REGION}-docker.pkg.dev` を実行してから `push` を再試行します。デプロイは同じコマンドを何度実行しても新しいリビジョンが作られるだけなので、失敗したらそのまま再実行して構いません。自分のデプロイがうまくいかないときは、講師が画面に映しているURLで体験に参加してください(この節の学習内容は変わりません)。

## 体験する

発行されたURLを全員で開き、メッセージを送り合ってみてください。

**リアルタイムに全員の画面へ配信されます。**

いま起きていることを整理すると:

- ロードバランサーも API Gateway も立てていない
- 接続管理のための DynamoDB 相当も書いていない
- コードはローカルで `docker run` してもそのまま動く、教科書通りの WebSocket サーバー

**成功していれば:** 自分が送ったメッセージが、他の参加者の画面にもほぼ同時に表示されます。 **詰まったら:** メッセージが届かない・送れなくなった場合は、まずページを再読み込みして接続を張り直してください。WebSocket の接続はリクエストタイムアウトの対象で、`--timeout` を伸ばしていないサービスでは既定の5分で切断されます。自分でデプロイしたサービスで一部の人にだけ届かない場合は、`--max-instances 1` を付け忘れているか確認してください(このデモは接続をインスタンスのメモリで管理しているため、インスタンスが増えると接続先ごとに分断されます)。心当たりがあれば「デプロイ手順」のコマンドをそのまま再実行すれば設定が入ります。`--session-affinity` はベストエフォートなので、これだけでは同じインスタンスに集まることは保証されません。`gcloud run services describe handson-chat --region ${REGION} --format 'value(status.url)'` で全員が同じURLを開いているかも確認してください。

## 実務で使うなら

- 状態共有: インスタンス間のブロードキャストは **Memorystore (Redis) の Pub/Sub** を挟むのが定番。そうすれば `--max-instances` の制限は外せます
- gRPC(双方向ストリーミング含む)や Server-Sent Events も同様にサポートされています。ただし gRPC のストリーミングには HTTP/2 が必要なので、デプロイ時に `--use-http2` を付けます。「**HTTPでできることは大体できる**」と覚えておけばOKです
- `--use-http2` は WebSocket には不要です。WebSocket は HTTP/1.1 の Upgrade で確立するので、このチャットアプリに `--use-http2` を付けると逆に応答しなくなります(公式ドキュメントも WebSocket では HTTP/2 の end-to-end 有効化を避けるよう案内しています)

# 10-3. Cloud Run Jobs

ここまで扱ってきたのは Cloud Run の「サービス」——HTTPリクエストを受けるワークロードでした。もう1つの顔が **Jobs**: リクエストを受けず、処理が終わったら終了するワークロードです。バッチ処理、DBマイグレーション、定期集計などに使います。

**AWSでいうと:** ECS の RunTask、AWS Batch、(15分制限がなければ)Lambda あたりの守備範囲です。

## サービスとの違い

|               | サービス              | Jobs                                |
|---------------|-------------------|-------------------------------------|
| 起動のきっかけ       | HTTPリクエスト         | 実行命令(手動 / スケジュール / API)             |
| 終わり方          | 常に待ち受け            | プロセスが exit したら完了                    |
| PORT の listen | 必須                | 不要                                  |
| 実行時間上限        | 60分(リクエストあたり)     | 最大7日間(タスクあたり)                       |
| 並列実行          | オートスケール           | タスク数・並列数を指定( <code>--tasks</code> ) |
| リトライ          | (Pub/Sub等の呼び出し側で) | <code>--max-retries</code> で組み込み    |

タスクあたり最大7日間という上限は、Lambda の15分と比べると使える場面の広さがよく分かります(重いデータ移行や機械学習の前処理がそのまま乗ります)。

重要なのは、**同じイメージ・同じレジストリ・同じ開発体験のまま**、Web とバッチの両方をカバーできることです。

## 1. ジョブを作って実行する

今日作ったイメージを流用し、起動コマンドだけ上書きしてジョブにします。

```
gcloud run jobs create handson-job \
  --image ${IMAGE}:v3 \
  --region ${REGION} \
  --command node \
  --args "-e,console.log('Hello from Cloud Run Jobs')"
```

実行します。

`--wait` で完了まで待ちます。

```
gcloud run jobs execute handson-job --region ${REGION} --wait
```

ログを見てみましょう:

```
gcloud run jobs logs read handson-job --region ${REGION}
```

コンソールの [Cloud Run](#) では「ジョブ」タブに実行履歴・成功/失敗・ログが並びます。

**成功していれば:** `--wait` を付けた実行は完了まで戻ってこず、`Creating execution...` → `Provisioning resources...done` → `Starting execution...done` → `Running execution...done` を経て `Execution [handson-job-xxxxx] has successfully completed.` で終わります(20~30秒ほどかかります)。ジョブ作成時は `Job [handson-job] has successfully been created.` が出ます。`gcloud run jobs list --region ${REGION}` に `handson-job` が並び、ログに `Hello from Cloud Run Jobs` が出ます。**詰まったら:** ジョブの実行は非同期なので、ログはすぐには出そりません。`--wait` を付け忘れた場合は数十秒待ってから `gcloud run jobs logs read handson-job --region ${REGION}` をもう一度実行してください。`ALREADY_EXISTS` は作成済みという意味なので、そのまま実行のコマンドへ進みます。イメージが見つからないと言われる場合は、`echo ${IMAGE}` が空でないかを確認し、空なら4章の「0. 環境変数の準備」を再実行してください。`:v3` が存在しない場合は `gcloud artifacts docker images list ${REGION}-docker.pkg.dev/${PROJECT_ID}/${REPO} --include-tags` で push 済みのタグを確認し、そこにあるタグ(`:v1` など)に読み替えて作成コマンドを実行して構いません。作り直したいときは `gcloud run jobs delete handson-job --region ${REGION} --quiet` で消してから、この節の作成コマンドをもう一度実行します。

## 2. 定期実行(cron)にする

Cloud Scheduler(EventBridge Scheduler 相当)から叩けば cron バッチになります。

コンソールのジョブ詳細画面から「トリガー」→「スケジューラ トリガーを追加」で GUI から設定できます。

CLI でやる場合は、Scheduler がジョブを起動するための**専用サービスアカウント**を作り、必要最小限の権限(`run.invoker`)だけを与えます(AWS で EventBridge Scheduler に実行ロールを作るのと同じ発想です)。

*# Scheduler がジョブを起動するための専用サービスアカウント*

```
gcloud iam service-accounts create handson-scheduler
```

```
gcloud run jobs add-iam-policy-binding handson-job \
  --region ${REGION} \
  --member "serviceAccount:handson-scheduler@${PROJECT_ID}.iam.gserviceaccount.com" \
  --role roles/run.invoker
```

*# 例: 毎朝9時(JST)に実行するトリガー*

```
gcloud scheduler jobs create http handson-job-schedule \
  --location ${REGION} \
  --schedule "0 9 * * *" \
  --time-zone "Asia/Tokyo" \
  --http-method POST \
  --uri "https://run.googleapis.com/v2/projects/${PROJECT_ID}/locations/${REGION}/jobs/handson-job:run" \
  --oauth-service-account-email "handson-scheduler@${PROJECT_ID}.iam.gserviceaccount.com"
```

こちらはコマンドが少し長いので、イベントでは GUI での設定を見せるだけで十分です。IAM 付与の直後は反映まで数分かかり 403 が返ることがあります——初回実行が失敗したら少し待ってリトライしてください。

**成功していれば:** `gcloud scheduler jobs list --location ${REGION}` に `handson-job-schedule` が `ENABLED` で並びます。サービスアカウントは `gcloud iam service-accounts list` に `handson-scheduler@...` として出ます。**詰まったら:** サービスアカウントと IAM 付与のコマンドは何度実行しても同じ結果になるので( `ALREADY_EXISTS` はそのまま次へ)、順番に再実行して構いません。作成した直後に IAM 付与を実行すると `INVALID_ARGUMENT: Service account handson-scheduler@... does not exist.` で失敗することがあります——これはサービスアカウント作成の反映待ちなので、数十秒おいて IAM 付与のコマンドだけをもう一度実行してください。Cloud Scheduler の API が有効でないというエラーが出た場合は `gcloud services enable cloudscheduler.googleapis.com` を実行してから、スケジューラー作成のコマンドをやり直してください。上記のとおり反映待ちで最初の起動が 403 になることがあるので、ジョブ自体が動く状態かを確認めたいときは数分待ってから `gcloud run jobs execute handson-job --region ${REGION} --wait` で手動実行が成功するかを見てください。 `${PROJECT_ID}` や `${REGION}` が空のままだとメンバー名や URI が壊れるので、その場合は 4章の「0. 環境変数の準備」を再実行してからやり直します。この節は本編の内容ではないので、うまくいかなければコンソールの GUI 設定を見るだけにして次へ進んで構いません。

### 3. 並列実行

Jobs の面白いところは組み込みの並列実行です。

例えば「10万件のデータを100タスクで分担して処理」のような使い方ができます:

```
gcloud run jobs update handson-job --region ${REGION} --tasks 5
gcloud run jobs execute handson-job --region ${REGION} --wait
```

各タスクには `CLOUD_RUN_TASK_INDEX` / `CLOUD_RUN_TASK_COUNT` という環境変数が渡されるので、「自分は何番目か」で担当範囲を割り出せます。

AWS Batch の配列ジョブ相当が、追加サービスなしで使えます。

#### [要作図] 図10: 並列タスクが担当範囲を分ける仕組み

- **目的:** `CLOUD_RUN_TASK_INDEX` だけで分担が決まるという、コードを書く側の視点を示す
- **描き方:** 1つのジョブから5つのタスクが同時に立ち上がる形。各タスクの箱に渡される環境変数と、そこから導かれる担当範囲を並べる
  - タスク0: `INDEX=0` / `COUNT=5` → 1～20,000件目
  - タスク1: `INDEX=1` / `COUNT=5` → 20,001～40,000件目
  - (以下同様に5つ)
- **要点:** キューもディスパッチャも書いていないこと。環境変数2つで分担が決まるという単純さがこの機能の価値
- **補足:** 実測では5タスクがほぼ同時(同一秒)に起動した例もあり、直列ではなく並列であることを図でも表現したい(5つの箱を横並びにして同時性を示す)

- **完成後の扱い:** 10\_advanced/imgs/parallel-tasks-index.png として保存し、**見出しの直下**に !**[並列タスクが環境変数で担当範囲を分ける仕組み]**(imgs/parallel-tasks-index.png) として差し込む(見出し → 画像 → 本文の順。キャプション文は付けない)

## 後片付け(この節の分)

```
gcloud scheduler jobs delete handson-job-schedule --location ${REGION} --quiet # 作った場合のみ
gcloud iam service-accounts delete "handson-scheduler@${PROJECT_ID}.iam.gserviceaccount.com" --quiet # 作った場合のみ
gcloud run jobs delete handson-job --region ${REGION} --quiet
```



## 99. 後片付け

お疲れさまでした!課金が発生し続けるリソースを片付けます。

### おすすめ: プロジェクトごと削除

ハンズオン専用プロジェクトで進めた場合は、これが一番確実です。

```
gcloud projects delete ${PROJECT_ID}
```

(30日間は復元可能な状態で保留されたあと、完全に削除されます)

### 個別に削除する場合

既存プロジェクトを使った場合はこちら。Cloud Shell を開き直していると `${REGION}` などの環境変数が消えているので、先に [4章の「環境変数の準備」](#) を実行し直してください。

*# Cloud Run サービス*

```
gcloud run services delete handson-app --region ${REGION} --quiet
gcloud run services delete handson-app-src --region ${REGION} --quiet # 9章を実施した場合
gcloud run services delete handson-chat --region ${REGION} --quiet # 10-2を実施した場合
```

*# Cloud Scheduler とサービスアカウント(10-3を実施した場合)*

```
gcloud scheduler jobs delete handson-job-schedule --location ${REGION} --quiet
gcloud iam service-accounts delete "handson-scheduler@${PROJECT_ID}.iam.gserviceaccount.com" --quiet
```

*# Cloud Run ジョブ(10-3を実施した場合)*

```
gcloud run jobs delete handson-job --region ${REGION} --quiet
```

*# Pub/Sub(10-1を実施した場合)*

```
gcloud pubsub subscriptions delete handson-sub
gcloud pubsub topics delete handson-topic
```

*# Artifact Registry(イメージの保管料がかかるため忘れずに)*

```
gcloud artifacts repositories delete ${REPO} --location ${REGION} --quiet
# 9章のソースデプロイは cloud-run-source-deploy というリポジトリを自動で作るため、こちらも削除します
gcloud artifacts repositories delete cloud-run-source-deploy --location ${REGION} --quiet
```

*# 9章のソースデプロイは Cloud Build 用のバケットも自動で作ります(アップロードしたソースが残ります)*

```
gcloud storage rm --recursive gs://${PROJECT_ID}_cloudbuild --quiet
```

このバケットは `--region` に追従せず US マルチリージョンに作られるので、`gcloud storage ls` で探すときはリージョンで絞らないでください。

**課金ポイントの整理:** Cloud Run はスケールtoゼロなので、`min-instances` を0に戻してあれば放置してもほぼ課金されません(1以上のままだとアイドル状態でも課金され続けます)。継続課金になり得るのは **Artifact Registry のストレージ**(無料枠は課金アカウントあたり0.5GB/月)、**min-instances**、そして **Cloud Scheduler のジョブ**(無料枠は課金アカウントあたり3ジョブ/月)です。

**講師の方へ:** 当日のサポートアプリ( `handson-support` )は上の一覧に含まれていません。`--min-instances 1` で動いているためアイドル状態でも課金が続くので、リポジトリの `support/README.md` の「後片付け」節も実行してください(受講者の方はこの節は不要です)。

## 消し忘れが心配な人へ

[課金レポート](#) で数日後に確認するか、予算アラート(Budgets & alerts)を設定しておくで安心です。AWS の Budgets と同じ感覚で使えます。

## 続けて学びたい人へ

- [Cloud Run 公式ドキュメント](#) — 品質が高く日本語も充実
- [introduction-docker](#) — Docker を基礎から
- [クラウドを今から学ぶには](#) — 非機能要件の考え方
- 次の一步: Cloud Build トリガーで「git push したら自動デプロイ」、Secret Manager 連携、`--no-allow-unauthenticated` + IAM でのサービス間認証、Cloud SQL 接続あたりが実務への近道です